



Högskoleingenjörsutbildning i datateknik

Grundnivå, 15hp

Ett system för talangutveckling inom ungdomsfotboll

ALEXANDER NYSTRÖM

Ett system för talangutveckling inom ungdomsfotboll

A Systems Approach to Talent Development in Youth Football

Alexander Nyström

Examensarbete inom datateknik
Grundnivå, 15 hp
Handledare på KTH: Adam Darwich
Examinator: Ibrahim Orhan
TRITA-CBH-GRU-2024:319

KTH
Skolan för kemi, bioteknologi och hälsa
141 52 Huddinge, Sverige

Sammanfattning

Effektiv datahantering och analys är avgörande i sportvärlden för att förbättra spelarutveckling och prestationer. Detta examensarbete har utvecklat en applikation som förbättrar hanteringen och analysen av fotbollsstatistik för ungdomslag genom användning av relations- och grafdatabaser. Applikationen hanterar inkonsekvenser i data från olika plattformar och möjliggör dynamisk datahantering samt visuell representation, vilket underlättar för tränare att göra mer effektiva utvärderingar och beslut. Genom att använda bayesianska nätverksmodeller identifierades de mest inflytelserika variablerna för spelarnas prestationer, vilket ger insikter för optimering av träningsstrategier.

Resultaten indikerar att applikationen har centraliserat och strukturerat dataintegration, vilket förbättrar tillgängligheten och förståelsen av data, samt skapar möjligheter för vidare forskning inom sportanalytik. Analysen med bayesianska nätverksmodeller avslöjade starka korrelationer mellan AIK:s kvalitativa betyg, samt att Chains PG (antal bollenhavssekvenser) hade störst påverkan på de summerade betygen för samtliga plattformar. Denna insikt erbjuder värdefulla riktlinjer för att optimera träningsstrategier. Framstegen öppnar för fortsatt utveckling av komplexa systemmodeller som kan ytterligare förbättra beslutsstödsprocesserna inom ungdomsfotboll.

Nyckelord

Ungdomsfotboll, dataanalys, bayesianska nätverksmodeller, dataintegration, grafdatabaser, relationsdatabaser, datakonsistens, visualisering, sportstatistik, beslutstödssystem.

Abstract

Effective data management and analysis are crucial in the world of sports to enhance player development and performance. This thesis has developed an application that improves the management and analysis of football statistics for youth teams using relational and graph databases. The application handles inconsistencies in data from various platforms and enables dynamic data management and visual representation, which facilitates more effective evaluations and decision-making by coaches. By using Bayesian network models, the most influential variables for player performance were identified, providing insights for optimizing training strategies.

The results indicate that the application has centralized and structured data integration, improving the accessibility and understanding of data, and creating opportunities for further research in sports analytics. The analysis with Bayesian network models revealed strong correlations between AIK's qualitative scores and that Chains PG (number of ball possession sequences) had the most significant impact on the aggregated scores across all platforms. This insight offers valuable guidelines for optimizing training strategies. The progress opens for the continued development of complex system models that can further enhance decision-support processes in youth football.

Keywords

Youth football, data analysis, Bayesian network models, data integration, graph databases, relational databases, data consistency, data visualization, sports statistics, decision support systems.

Innehållsförteckning

1	Inledning.....	1
1.1	Problemformulering.....	1
1.2	Målsättning.....	1
1.3	Avgränsningar.....	2
1.4	Författarens bidrag till examensarbetet.....	3
2	Teori och bakgrund	5
2.1	Teoretiska ramverk.....	5
2.1.1	Begrepp	5
2.2	Litteraturstudie	5
2.2.1	Sportdata och dess hantering	5
2.2.2	Databasteknologier i sportanalys	6
2.2.3	Statistiska metoder och datavisualisering	7
2.2.4	Bayesiansk nätverksanalys.....	8
2.3	Arkitekturmönster	9
2.3.1	Komponentbaserad arkitektur	9
2.3.2	Service-Repository-Controller-mönstret	9
2.4	Datavariabler.....	9
2.5	Modellering och dataanalys.....	10
2.5.1	Regressionsanalys	10
2.5.2	Maskininlärning (ML).....	10
2.5.3	Bayesiansk nätverksanalys.....	10
2.5.4	Val av bayesiansk nätverksmodell	11
3	Metoder.....	13
3.1	Beslut av metoder	13
3.1.1	Motivering till valet av MySQL.....	13
3.1.2	Användning av Neo4J för grafdatabasbehov	14
3.2	Tillvägagångssätt för applikationsutveckling	14
3.2.1	Hantering av olika CSV format	14
3.2.2	Unik identifierare för respektive dataset	15
3.2.3	Utveckling av backend för koppling till MySQL databas	15
3.2.4	Utveckling av backend för koppling till Neo4J databas	17
3.2.5	Utveckling av frontend-applikationen	18
3.2.6	Datainsamling.....	19
3.2.7	Utmaningar och strategier för visualisering av data i diagram	20

3.3	Tillvägagångssätt för dataanalys och modellering	21
3.3.1	Installation av Python och nödvändiga paket	22
3.3.2	Analysera normalfördelning med Histogram och QQ-plottning	22
3.3.3	Analysera korrelationsmatrisen	23
3.3.4	Analysera relationer med regressionsplottning	24
3.3.5	Utveckling av bayesiansk nätverksmodell	25
4	Resultat.....	27
4.1	Representation av datan	27
4.1.1	Exempel på diagram från enskilda matcher för vald parameter	27
4.1.2	Exempel på diagram från samtliga matcher för vald parameter	28
4.1.3	Exempel på tabell för enskild match	28
4.1.4	Exempel på nätverksvisualisering av matchdeltagande	29
4.2	Verifiering och validering	29
4.2.1	Funktionstest av datavisualisering	29
4.2.2	Validering av användarvänlighet	30
4.2.3	Kontroll av Datainkonsistenser	30
4.3	Resultatet av dataanalysen	31
4.3.1	Resultat av normalfördelning	31
4.3.2	Resultat av korrelationsmatris	32
4.3.3	Resultat av regressionsplottningar	33
4.4	Resultat av bayesiansk nätverksanalys	36
4.4.1	Jämförelse mellan summerade betyg från plattformarna	36
4.4.2	Bayesiansk nätverksmodell	38
4.4.3	Inferensanalys mellan summerade betyg och AIK:s kvalitativa mätningar	39
4.4.4	Resultat av inferens från bayesiansk nätverksmodell	40
5	Analys och diskussion	43
5.1	Analys över dynamisk datahantering	43
5.1.1	Förbättringspotential.....	44
5.2	Analys över filformat	44
5.2.1	Förbättringspotential.....	44
5.3	Analys om persistent lagring	44
5.3.1	Förbättringspotential.....	44
5.4	Analys om integreringen av neo4j grafdatabas	45
5.4.1	Förbättringspotential.....	45
5.5	Analys av dataanalysen	45
5.5.1	Analys av normalfördelning	45
5.5.2	Analys av korrelationsmatriser	46

5.5.3	Analys av regressionsplottningar	46
5.5.4	Motivering till valet av Kendall för nätverksmodellen	48
5.5.5	Huvudsakliga fynd och begränsningar.....	48
5.6	Diskussion i förhållande till tidigare forskning - applikationen	49
5.6.1	Dataintegration i sportanalytik.....	49
5.6.2	Visualisering av sportdata.....	49
5.6.3	Datakvalitet och konsistens	49
5.6.4	Diskussion.....	49
5.7	Diskussion i förhållande till tidigare forskning – dataanalys.....	50
5.7.1	Bayesianska nätverksmodellens användbarhet.....	50
5.7.2	Vikten av föranalys	50
5.7.3	Val av korrelationsmått	50
5.8	Mål och förväntningar	50
5.9	Verifiering och framtida arbete	51
6	Slutsatser	53
	Källförteckning	55
	Bilagor	59
	Bilaga A – Resultat för dataanalysen av plattformen SoccerLab.....	59
	Bilaga B – Resultat för dataanalysen av plattformen EyeBall	62
	Bilaga C – Resultat för dataanalys av plattformen PlayMaker	65
	Bilaga D – Datavariabler för plattformarna	67
	Bilaga E – Resultat för de summerade betygen samt AIK:s kvalitativa betyg	70

1 Inledning

1.1 Problemformulering

I en alltmer digitaliserad sportvärld är exakt och konsistent data av stor vikt för tränare och ledare inom fotbollen. Med ett växande antal digitala plattformar som erbjuder omfattande statistik relaterad till spelare, matcher och lagprestationer, uppstår utmaningen att navigera och samordna divergerande datamängder. Dessa inkonsistenser i data skapar inte bara osäkerhet utan också ett betydande administrativt merarbete, då det kräver att ledarna måste verifiera och jämföra statistik för att garantera dess korrekthet.

Dessa problem underminerar tilltron till de verktyg som är avsedda att understödja strategiskt beslutsfattande och förbättra träningsmetoder och spelarförståelse. Den tid som används för att hantera dessa datainkonsistenser förhindrar tränare och ledare från att helt fokusera på utvecklingen av sina lag och spelare.

Inom lagsport och fotboll finns det ingen enhetlig konsensus om hur prestation bör definieras, vad de drivande faktorerna är, eller hur det ska mätas, vilket ytterligare komplicerar situationen. För att kunna förbättra träningsmetoder och fatta mer informerade beslut, är det nödvändigt att förstå de kausala sambanden mellan kvantitativa och kvalitativa data. Att identifiera och analysera dessa samband hjälper tränare och ledare att förstå hur olika faktorer påverkar varandra och bidrar till spelarnas prestationer.

Genom att implementera en grafdatabas, som är flexibel och väl lämpad för systemanalyser och uppdateringar, tar detta arbete sig an att skapa förutsättningar för att studera kausala samband mellan datan. Detta första steg mot en mer vetenskaplig och systematisk analys av sportdata kommer att öka tillförlitligheten i fotbollsstatistiken och därmed stärka beslutsfattandet inom sportvärlden.

För att ytterligare förbättra analysen av komplexa samband och osäkerheter i sportdata, kommer en bayesiansk nätverksmodell att implementeras. Bayesianska nätverk är kraftfulla verktyg för att modellera och analysera probabilistiska relationer mellan variabler. Implementeringen av bayesianska nätverk möjliggör upptäckten av samband mellan olika faktorer samt kvantifiering av osäkerheten i dessa samband. Detta är avgörande för att kunna fatta välgrundade och informerade beslut rörande tränings- och matchstrategier, vilket bidrar till en mer systematisk och tillförlitlig analys av sportdata.

1.2 Målsättning

De primära målen med detta examensarbete är att utveckla en innovativ applikation samt att utföra en dataanalys med hjälp av en bayesiansk nätverksmodell. Applikationen syftar till att möjliggöra för tränare och lagledare att få en omfattande och konsistent överblick av spelarprestationer samt att identifiera och förstå datainkonsistenser mellan olika statistikplattformar. Den bayesianska nätverksmodellen kommer att kartlägga korrelationer mellan variabler och utforska den kausala strukturen mellan dessa variabler i datan, vilket på sikt kan bidra till förbättrade träningsmetoder och strategiska beslut.

För att uppnå detta mål, kommer följande specifika delmål att vara i fokus:

Dynamisk datahantering: Applikationen kommer att utrustas med funktionalitet för att dynamiskt lägga till och bearbeta parametrar från csv-filer (comma separated values) relaterade till individuella fotbollsmatcher. Detta inkluderar förmågan att flexibelt anpassa och lägga till ytterligare parametrar över tid, vilket möjliggör en skräddarsydd och detaljerad analys av spelardata.

Formatanpassning: För att säkerställa en smidig dataintegration kommer applikationen att kunna hantera olika dataformat från de uppladdade csv-filerna. Denna flexibilitet är avgörande för att effektivisera arbetsflödet för användarna och underlätta integrationen av data från mångfaldiga källor.

Persistent lagring: Applikationen kommer att implementera mekanismer för persistent lagring av matchdata. Detta säkerställer att all insamlad och bearbetad information bevaras över tid, vilket underlättar longitudinella studier av spelarutveckling och lagprestationer samt ger en robust grund för analys av dataöverensstämmelse mellan olika plattformar.

Integration av Neo4j grafdatabas: För att ytterligare stärka applikationens förmåga att identifiera, analysera komplexa relationer mellan olika datamängder, kommer en Neo4j grafdatabas att integreras. Neo4j utnyttjar grafer för att effektivt representera och manipulera nätverksbaserade datastrukturer, vilket inte bara förbättrar visualiseringen och hanteringen av data utan även möjliggör dynamisk uppdatering och skalbarhet i datamodellen. Genom dess kapacitet att hantera komplexa relationer mellan entiteter, som spelare och matcher, stödjer Neo4j djupgående analyser av samband och mönster, till exempel genom nätverksmodellering och maskininlärning, som är avgörande för att förstå dynamiken inom fotbollsstatistiken.

Neo4j grafdatabasen introducerar en betydande flexibilitet i databasstrukturen, vilket är kritiskt för att anpassa sig till framtida förändringar i datamodeller och användarbehov. Genom att tillämpa en grafdatabas lägger projektet också en grund för fortsatt forskning inom området. Detta innebär att nya relationer och datapunkter kan integreras i systemet utan omfattande omstruktureringar, vilket underlättar kontinuerlig innovation och förbättring baserat på framtida forskningsresultat och tekniska framsteg.

Analysera relationer och påverkan: Utforska vilka variabler som har signifikanta samband med de summerade ratings som ges av olika plattformar för att förstå överensstämmelsen och avvikelser mellan plattformarna. Bestäm vilka variabler som har stor respektive liten påverkan på spelarprestationer.

Korrelation mellan AIK:s (Allmänna Idrottsklubbens) egna betygsättning: Utforska korrelationen mellan AIK:s egna betygsättningskategorier (Technique, Tactic, Mentality och Physique). Detta kommer att ge insikt i om dessa kategorier har starka samband med varandra och hur de påverkar den övergripande bedömningen av spelarnas prestationer.

1.3 Avgränsningar

Avgränsningar som detta arbete har haft är:

- Applikationen hanterar enbart data i CSV-format.
- Applikationen tillåter bara manuell uppladdning av data.
- All persistent data omvandlas till JSON-format.
- Ingen säker inloggningsfunktionalitet implementeras.
- Implementering av grafdatabas är endast avsedd för skapandet av noder för spelare och matcher samt deras relationer.
- Dataanalysen använder en bayesiansk nätverksmodell för att utforska variabelkorrelationer och möjliga kausala strukturer. Denna metod är väl lämpad att informera vidare utveckling av kausala systemmodeller i kommande forskningssamarbete.

Dessa avgränsningar är strategiska beslut som tagits för att balansera projektets ambitioner med de resurser och den tid som är tillgänglig. De utgör en viktig del av projektets ramar och ger insikt i de överväganden som har gjorts under utvecklingsprocessen. Begränsningarna är också beroende av hur data tillgängliggjordes för detta arbete.

1.4 Författarens bidrag till examensarbetet

Detta examensarbete omfattar design och programmering av en fullstack-applikation som centraliserar och hanterar data från AIK ungdomsfotbollslag. En central del av arbetet var att utföra en dataanalys för att identifiera och kartlägga de kausala sambanden mellan variabler. Jag har självständigt genomfört alla faser, från insamling av data till utveckling och implementering av både frontend och backend, samt integrering av data från flera olika plattformar till en enhetlig lösning.

2 Teori och bakgrund

Inledningsvis presenteras de huvudsakliga begreppen som kommer tas upp under arbetet, en litteraturstudie och avslutningsvis en överblick på vilka plattformar som används i dag av för att få ut statistik om matcherna som spelas av AIKs ungdomslag.

2.1 Teoretiska ramverk

2.1.1 Begrepp

Pearson-korrelation är en statistisk metod som mäter graden av linjär association mellan två kontinuerliga variabler. Den används för att kvantifiera hur starkt två variabler är relaterade till varandra. För att använda Pearson-korrelationen bör båda variablerna vara normalfördelade, och det antas att det finns en linjär relation mellan dem (1).

Spearman-korrelation är en icke-parametrisk metod som mäter den rangordnade associationen mellan två variabler. Istället för att fokusera på de exakta värdena använder Spearman rankningarna av variablerna. Den är användbar när data inte är normalfördelad eller när vi har ordinalskalade variabler. Spearman-korrelationen är mindre känslig för extrema värden och fungerar bra även när associationen inte är strikt monoton (1).

Kendall's tau är en annan icke-parametrisk metod för att mäta rangordnad association. Den liknar Spearman-korrelationen och används när det finns ordinalskalade variabler eller när data inte är normalfördelad. Kendall's tau är robust mot utliggare (en: outliers) och fungerar bra även när associationen inte är strikt monoton (1).

2.2 Litteraturstudie

2.2.1 Sportdata och dess hantering

Data och statistik har fått en alltmer betydande roll inom sport för att mäta och prediktera prestationer och resultat, samt informera beslutsfattande. I sin artikel ger Bai *et al.* (2) en omfattande genomgång av hur stora datamängder inom sport, särskilt inom idrottsprestationer och träning, kan hanteras, analyseras och användas. I studien belyses vikten av att hantera och analysera stora datamängder för att optimera prestationer och utveckla strategier inom sportindustrin. Författarna diskuterar även tekniska utmaningar och möjligheter som finns i att samla in, säkra och behandla dessa datamängder. De introducerar konceptet "sports big data" som innehåller omfattande och varierade data från olika källor som internet och sensorer, vilka erbjuder rik information om atleter, tränare och sportevenemang. Denna data sträcker över många olika dimensioner som fysisk kondition, träningsbeteenden och personlig information, vilket kräver avancerade metoder för datahantering och dataanalys.

För att hantera dessa stora datamängder och göra dem användbara i praktiken, betonar Few (3) vikten av att kunna visualisera longitudinella studier effektivt. Detta underlättar för användare av en applikation att tolka data. Visualiseringstekniker är avgörande för att presentera sportstatistik på ett lättförståeligt och analytiskt sätt. Genom att använda diagram och tabeller kan informationen visas tydligt och ge användaren en bättre förståelse.

Dessutom understryker Wexler *et al.* (4) att valet av rätt teknik för dataframställning är avgörande. Speciellt viktigt är valet av rätt diagramtyp för att säkerställa att visualiseringen är informativ och

användbar. Applikationsbiblioteket Chart.js är särskilt värdefullt i detta sammanhang, eftersom det är effektivt för att skapa stapeldiagram (5). Wexler *et al.* (4) förklarar att stapeldiagram är väl lämpade för att göra enkla jämförelser mellan olika mätvärden, vilket gör det lätt för användare att snabbt tolka och förstå data. De motiverar att korrekt val av diagram och färgsättning är essentiellt för att maximera klarheten och nyttan med visualiseringarna.

För att förstå begränsningar med sportdata utforskar Vaughan *et al.* (6) det ekologiska perspektivet inom sport, specifikt fotboll, genom att integrera Skilled Intentionality Framework (SIF). Ramverket belyser hur spelares interaktion med sin omgivning påverkas av sociala, kulturella och historiska faktorer, vilket formar utvecklingen av färdigheter hos unga fotbollsspelare. Studien betonar miljöns roll, som är "belastad" med social och kulturell betydelse, vilket påverkar spelarnas perception och handlingar under spelet.

Huvudbidraget från artikeln (6) till idrottsvetenskapen är dess illustration av hur ekologiska dynamiker kan tillämpas för att förstå och förbättra idrottares utveckling bortom traditionella metoder. Författarna argumenterar för att den sociala och historiska kontexten där spelarna lär sig och spelar fotboll formar deras färdighetsutveckling genom kontinuerlig interaktion med möjliggörare i deras miljö. Dessa möjliggörare är möjligheter till handling som miljön tillhandahåller, vilka uppfattas olika av varje spelare baserat på deras personliga och kulturella bakgrund.

Studien (6) utforskar även konceptet "värderingsinriktning" i spelarmiljöinteraktioner. Denna teori beskriver hur spelares handlingar inte bara är svar på miljöns fysiska egenskaper utan även styrs av värden som uppstår från sportens kulturella och sociala sammanhang. Till exempel kan sättet fotboll spelas och de färdigheter som värderas skilja sig avsevärt mellan olika kulturer, vilket påverkar hur tränare tränar spelare och hur spelare uppfattar och agerar i spelsituationer.

Vaughan *et al.* (6) föreslår att förståelsen för dessa ekologiska och relationella begrepp kan förbättra träningsmetoder avsevärt. Genom att erkänna de kulturella och sociala begränsningar som påverkar spelarutveckling kan tränare bättre utforma träning som är i linje med spelarnas perceptuella verkligheter, vilket främjar en mer effektiv inlärnings- och prestandamiljö.

Detta ekologiska perspektiv (6) är särskilt relevant för utvecklingen av sportanalysplattformar, som den som designas i detta examensarbete. Genom att integrera dessa koncept kan sådana plattformar mer exakt återspegla komplexiteten i spelarinteraktioner och utveckling, med hänsyn inte bara till de fysiska utan även de sociala och kulturella dimensionerna av idrott. Detta tillvägagångssätt stödjer en mer nyanserad analys av spelardata, vilket leder till insikter som är kulturellt och kontextuellt informerade, vilket i slutändan förbättrar de strategiska beslut som fattas av tränare och sportanalytiker.

2.2.2 Databasteknologier i sportanalys

För att effektivt hantera data utforskar Vicknair *et al.* (7) användningen av en graf-databas (Neo4j) och en relationsdatabas (MySQL) för hantering av data med komplexa relationer, speciellt inom området för dataursprung (en: data provenance). Studien fokuserar på hur dessa databastyper hanterar lagring och frågor relaterade till direkt acykliska grafer (DAGs), vilket är en vanlig struktur för att spåra dataursprung där noderna representerar dataposter och kanterna relationer mellan dessa poster. Författarna analyserar prestanda, skalbarhet och användarvänlighet mellan de två databassystemen genom att genomföra en serie benchmark-tester. Dessa tester inkluderar mätningar av hastighet för olika typer av frågor, inklusive traversering av grafer och dataförfrågningar. Resultaten visar att Neo4j presterar bättre för frågor som involverar komplexa graftraverseringar, medan MySQL är mer effektivt för enkla sökrågor på grund av dess optimerade indexering för relationella datastrukturer.

2.2.2.1 Fördelar och nackdelar med olika databastyper

Relationsdatabaser, såsom MySQL, erbjuder strukturerad datahantering med starka relationer mellan tabeller, robust stöd för komplexa frågor och väletablerad dokumentation (8). MySQL är känd för sin stabilitet, skalbarhet och säkerhet, med stöd för ACID-egenskaper som säkerställer dataintegritet och säkerhet, vilket är kritiskt för applikationer med strikta krav på datakonsistens. Nackdelarna inkluderar mindre flexibilitet vid schemaändringar och potentiella prestandaproblem vid hantering av stora datamängder. Dokumentorienterade databaser, som MongoDB, stödjer schemalösa datastrukturer och är effektiva för skalning samt hantering av semi-strukturerade data som JSON. Dock är komplexa frågor och transaktioner mer begränsade jämfört med relationsdatabaser.

Grafdatabaser, såsom Neo4J, erbjuder hög skalbarhet och är fullt transaktionella med stöd för ACID-egenskaper, vilket säkerställer dataintegritet och säkerhet i komplexa datamiljöer (9). Neo4j användning av Cypher, ett kraftfullt frågespråk för grafdata, förbättrar effektiviteten vid sökning och hantering av stora mängder data. Denna typ av databas är särskilt fördelaktig när det gäller att analysera och visualisera relationer mellan olika dataenheter. Nackdelarna inkluderar högre kostnader för implementering och underhåll samt en brant inlärningskurva för utvecklare (10). Objektorienterade databaser, såsom ObjectDB, är väl lämpade för att hantera JSON eftersom JSON naturligt representerar data i objektform, vilket kan förenkla utvecklingsprocessen (11). Men de är mindre effektiva än andra databastyper för att hantera stora datamängder och kräver ofta mer komplex konfiguration och underhåll (12).

2.2.3 Statistiska metoder och datavisualisering

En noggrann föranalys av data är avgörande för att säkerställa att den valda modellen passar data väl och ger tillförlitliga resultat. Field (13) understryker vikten av att fastställa om data är normalfördelad, linjär samt monoton innan analysen påbörjas. Många statistiska test och modeller, inklusive regressionsmodeller, antar att data är normalfördelad, och avvikelser från detta antagande kan påverka validiteten av dessa test och modeller. En normalfördelning innebär att data är symmetriskt fördelad runt medelvärdet och har formen av en så kallad klockkurva (en: *bell curve*). Detta är en förutsättning för många parametriska tester eftersom det tillåter prediktioner och inferenser om populationer baserat på urval. Ett linjärt samband refererar till ett proportionellt samband mellan två variabler, vilket innebär att en förändring i en variabel medför en proportionell förändring i den andra. En monoton relation mellan variabler innebär att en variabel kontinuerligt ökar eller minskar i förhållande till en annan utan att ändra riktning, vilket kan mätas med hjälp av till exempel Spearman rankkorrelation eller Kendall tau. Vidare påstår författaren att regressionsanalys är en kraftfull metod för att undersöka samband mellan variabler och för att göra prognoser. Genom att använda regressionsplottning kan dessa samband visualiseras, vilket ger en tydligare bild av datans struktur och hur olika variabler påverkar varandra.

Enligt Ghasemi och Zahediasl (14) är histogram ett viktigt verktyg för att grafiskt representera fördelningen av data (till exempel om data är normalfördelat). Genom att dela upp data i intervaller kan histogram avslöja mönster som symmetri, skevhet och multimodalitet. QQ-plottningar (Quantile-Quantile plots) används för att visuellt jämföra en dataset mot en teoretisk fördelning, oftast en normalfördelning. Om data är normalfördelad ligger punkterna längs en 45-graders linje. Avvikelser från denna linje indikerar avvikelser från normalfördelningen, vilket kan påverka valet av statistiska tester och modeller.

Vidare understryker Field (13) att valet av korrelationsmått beror på datafördelningen och relationen mellan variablerna. Pearson korrelationskoefficient är bäst lämpad för linjära relationer när data är normalfördelad, då den mäter graden av linjärt samband mellan två variabler. För att mäta monotona

relationer och hantera data som inte är normalfördelad, används Spearman rankkorrelation, som är robust mot outliers och lämpad för ordinala data. Kendall tau mäter också monotona relationer och är användbar när datauppsättningarna är små eller innehåller många lika värden.

Mukaka (15) beskriver att Pearson korrelationskoefficient används för att mäta graden av linjärt samband mellan två kontinuerliga variabler och förutsätter att data är normalfördelad. Pearson-korrelation är känslig för outliers som kan snedvrider resultaten. Spearman rankkorrelation, enligt Mukaka, är en icke-parametrisk metod som mäter styrkan och riktningen av monotona samband mellan två variabler och är robust mot outliers, vilket gör den lämplig för ordinala data eller data som inte är normalfördelad. Bonett och Wright (16) nämner att Kendall tau är en annan icke-parametrisk korrelationskoefficient som mäter ordningssamband mellan variabler. Den är särskilt användbar när dataset innehåller många lika värden eller är små, vilket gör den mer robust i vissa sammanhang.

2.2.4 Bayesiansk nätverksanalys

Bayesianska nätverksmodeller, enligt Korb *et al.* (17), är särskilt användbara för dataanalyser på grund av deras förmåga att hantera osäkerheter och komplexa beroenden mellan variabler. Dessa modeller representerar sannolikhetsfördelningar och beroenden i form av riktade acykliska grafer, där Bayes teorem används för att kontinuerligt uppdatera modellen med ny information. Denna flexibilitet och anpassningsbarhet gör bayesianska nätverksmodeller kraftfulla för inferens i situationer med osäker eller bristfällig information. Nielsen *et al.* (18) beskriver hur bayesianska nätverksmodeller är särskilt användbara inom medicinsk diagnostik och beslutsstödssystem. De betonar modellernas förmåga att representera komplexa beroenden mellan flera variabler, vilket är avgörande för att dra inferenser baserade på observerade data. Genom att möjliggöra en probabilistisk representation av osäkerhet förbättrar dessa modeller beslutsfattandet i komplexa system.

Probabilistisk inferens inom bayesianska nätverk innebär att beräkna den posteriora sannolikheten för en eller flera variabler, given evidens från andra variabler i nätverket (19). Detta görs genom att tillämpa Bayes' sats för att uppdatera sannolikhetsfördelningarna baserat på den tillgängliga informationen. Inferensprocessen gör det möjligt att dra slutsatser och förutsägelser trots osäkerhet eller ofullständiga data. Ding beskriver hur bayesianska nätverk kan användas för att svara på probabilistiska frågor genom att automatiskt tillämpa Bayes' sats på komplexa problem. I bayesianska nätverk leder uppdateringar av variabler i någon nod till evidenspropagering över hela nätverket. Denna propagering möjliggör beräkning av den posteriora fördelningen av variabler given evidens, vilket är kärnan i probabilistisk inferens.

Inom bayesianska nätverk bedöms den relativa påverkan som en variabel har på en annan variabel när den används som bevis. Detta koncept hjälper till att identifiera vilka variabler som har störst inflytande på en undersökt variabel inom nätverket. Enligt Needham *et al.* (20) används bayesianska nätverk för att identifiera nyckelvariabler i biologiska nätverk genom att analysera hur förändringar i en variabel påverkar sannolikheten för andra variabler.

För att kvantifiera denna påverkan beräknas skillnaden mellan sannolikheten för den undersökta variabeln med och utan den extra evidensvariabeln. Om sannolikheten för den undersökta variabeln förändras signifikant när en ny variabel introduceras som bevis, indikerar detta att variabeln har ett starkt inflytande. Denna metod används för att förstå hur olika faktorer bidrar till ett utfall och för att prioritera vilka variabler som är mest kritiska att övervaka eller manipulera i en given situation (20).

2.3 Arkitekturmönster

2.3.1 Komponentbaserad arkitektur

Komponentbaserad arkitektur (en: Component-based architecture) definieras som en designstrategi som främjar återanvändbarhet, underhåll och skalbarhet genom att bryta ner applikationer i modulära komponenter. Varje komponent inkapslar en specifik funktionalitet och interagerar med andra komponenter via väldefinierade gränssnitt (21).


Denna arkitekturtyp används flitigt i modern webbutveckling, speciellt inom ramverk som React. I React definieras varje komponent som en oberoende enhet med eget ansvar, vilket förenklar utvecklingsprocessen och underhåll av stora applikationer. Komponenter i React kan vara allt från enkel UI-knappar till hela sidor, vilket möjliggör en modulär och skalbar applikationsstruktur (22).

2.3.2 Service-Repository-Controller-mönstret

Service-Repository-Controller-mönstret är en arkitektur som vanligtvis används i backend-utveckling för att separera logik från användargränssnittet. Systemet delas in i tre huvudkomponenter:

- **Service:** Ansvarar för att utföra affärslogik och operationer. Den fungerar som en bro mellan kontrollern och repositoryt.
- **Repository:** Hanterar all dataåtkomstlogik och interaktioner med databasen.
- **Controller:** Tar emot användaranrop och delegerar operationer till rätt service. Det är det första mottagande lagret som hanterar HTTP-anrop och svar.

Denna arkitektur möjliggör tydlig separation av ansvar, vilket underlättar underhåll och skalbarhet. Controllers hanterar endast användarinput och vidarebefordran, medan servicelagret hanterar affärslogiken och repositories hanterar datalagring och återhämtning (23).



Figur 1: De olika nivåernas ansvarsområden – bild anpassad från Collings T (13).

2.4 Datavariabler

För att kunna genomföra analysen på ett strukturerat sätt är det viktigt att förstå de variabler som används från olika statistikplattformar. Denna studie använder data från tre huvudsakliga plattformar: SoccerLab, EyeBall och PlayMaker. För en detaljerad lista över samtliga datavariabler hänvisas till Bilaga D.

2.5 Modellering och dataanalys

När man analyserar data finns flera metodologiska verktyg tillgängliga, var och en med sina specifika fördelar och nackdelar. Bland de vanligaste metoderna ingår regressionsanalys, maskininlärning (ML) och Bayesiansk nätverksanalys.

2.5.1 Regressionsanalys

Regressionsanalys är en statistisk metod som används för att förstå förhållandet mellan en beroende variabel och en eller flera oberoende variabler (24).

- **Fördelar:** Regressionsanalys är lätt att förstå och implementera, vilket gör den till en enkel metod för många tillämpningar. Resultaten är ofta lätta att tolka, vilket gör det möjligt att dra tydliga slutsatser om relationerna i data. Den är effektiv för prediktiva modeller när det finns linjära samband (24).
- **Nackdelar:** Konventionella metoder är begränsade till linjära relationer och kan ha svårt att hantera icke-linjära samband eller icke-parametriskt data. Detta begränsar dess användbarhet för mer komplexa data som består av olika datatyper. Metoden är också känslig för outliers, vilket kan påverka resultatens noggrannhet. Vidare har den begränsad kapacitet att modellera komplexa beroenden och interaktioner mellan flera variabler och fokuserar ofta på modellering av en beroende variabel och vilka variabler som beskriver dess variation (24).

2.5.2 Maskininlärning (ML)

Maskininlärning omfattar en mängd olika algoritmer som kan lära sig från data och göra prediktioner. Exempel på ML-algoritmer inkluderar beslutsträd, supportvektormaskiner och neurala nätverk (25).

- **Fördelar:** Maskininlärning kan hantera stora datamängder och hitta komplexa mönster som inte är uppenbara med enklare metoder. Den är särskilt effektiv för att modellera icke-linjära relationer och interaktioner mellan variabler. Dessutom är ML-algoritmer mycket anpassningsbara och kan tillämpas på olika typer av data och problem (25).
- **Nackdelar:** Dessa metoder kan vara svåra att tolka och förklara, vilket kan göra det utmanande att förstå hur beslut tas. De kräver ofta stora mängder data för att fungera effektivt och kan vara resurskrävande vad gäller beräkningskapacitet och tid för modellträning (25).

2.5.3 Bayesiansk nätverksanalys

Bayesiansk nätverksanalys använder probabilistiska grafmodeller för att representera variabler och deras beroenden genom riktade acykliska grafer (DAG). Denna metod är särskilt användbar för att hantera osäkerhet och komplexa beroenden (17).

- **Fördelar:** Bayesianska nätverk är mycket effektiva för att hantera osäkerhet, eftersom de använder sannolikheter för att representera osäkerheter i relationer mellan variabler. Den grafiska strukturen gör det enkelt att visualisera och förstå beroenden, vilket underlättar identifiering av orsaks-samband. Dessutom kan tidigare kunskap och expertbedömningar inkluderas i modellen, vilket förbättrar dess noggrannhet och robusthet. Bayesianska nätverk är också flexibla och skalbara, vilket gör dem användbara för att hantera både diskreta och kontinuerliga variabler i stora datasets (17).

- Nackdelar: Trots sina fördelar kan Bayesianska nätverk vara komplexa att konstruera och kalibrera, vilket kan vara tidskrävande och kräva betydande expertis. De kan också kräva mycket beräkningsresurser, särskilt när man arbetar med stora och komplexa nätverk. Dessutom kan de behöva omfattande data för att skapa tillförlitliga modeller (17).

2.5.4 Val av bayesiansk nätverksmodell

Valet av Bayesiansk nätverksmodell för denna studie motiveras av flera skäl. För det första förväntas datasetet vara litet, och bayesianska nätverk är särskilt lämpade för att hantera små dataset eftersom de kan integrera tidigare kunskap och expertbedömningar för att förbättra modellens noggrannhet (18). För det andra finns det komplexa samband mellan variablerna i studien, och bayesianska nätverk är utformade för att hantera sådana komplexa beroenden genom sin grafiska struktur som visualiserar relationer och osäkerheter (17). Slutligen gör modellens flexibilitet och anpassningsbarhet den särskilt kraftfull för inferens i situationer med osäker eller bristfällig information, vilket är en vanlig utmaning i många forskningssammanhang.

Bayesianska nätverksmodeller ger även en första indikation om modellstruktur för vidare utveckling av systemmodeller i framtida studier. Detta är särskilt relevant då både Bayesianska nätverk och kausala nätverksanalyser baseras på identifiering av kausala relationer i komplex data och teori (17). Genom att kartlägga sannolikhetsbaserade relationer och beroenden mellan variabler, kan Bayesianska nätverk hjälpa till att bygga en grund för mer omfattande systemmodeller som används för att förstå och förutsäga dynamiska system. Denna typ av modellering är särskilt användbar inom komplexa system där interdependenta variabler (*en: interdependent variable*) spelar en kritisk roll i systemets beteende.

Forskningen av Ameer *et al.* (31) bekräftar användningen av bayesianska nätverk för att hantera små och ofullständiga datamängder genom att effektivt integrera och hantera osäkerheter och saknade data, vilket är direkt relevant och stärker det metodologiska valet i detta arbete. Forskningen av Fuster-Parra *et al.* (32), D'Urso *et al.* (33), och Olmedilla *et al.* (34) stödjer även valet av bayesianska nätverk genom att visa på modellernas förmåga att hantera komplexa datamängder, visualisera osäkerheter och integrera multivariata relationer utan att förlita sig på normalfördelade data. Dessa studier understryker bayesianska nätverks flexibilitet och anpassningsbarhet vid modellering av dynamiska och osäkra system, vilket är av central betydelse i denna studie och illustrerar vetenskaplig robusthet och relevans i det metodologiska tillvägagångssättet.

3 Metoder

Inledningsvis utfördes en förstudie om typiska format som användes bland statistikplattformarna för att kunna hitta och utveckla en logik som dynamisk kan hantera nuvarande samt framtida fil-format och input-parametrar. En litteraturstudie genomfördes kring insamling av sportdata och hur man förenklar hanteringen av fotbollsstatistik. Därefter utvecklades en implementering för att ge en unik identifierare för varje matchdata från de unika statistikplattformarna för att enklare kunna identifiera från vilken plattform varje statistik kommer ifrån. Vidare gjordes en ytterligare implementering för att hantera lagring av data för grafdatabasen Neo4J. Slutligen utvecklades en frontend-applikation som låter användaren interagera med applikationen. Under utvecklingsprocessen utvärderades visualiseringsprototypen för att säkerställa att de bästa metoderna för att presentera fotbollsstatistik användes.

Denna studie syftade även till att utveckla en dataanalysmodell för fotbollsmatcher med hjälp av en bayesiansk nätverksmodell. Först genomfördes en förstudie om användningen av bayesianska nätverksmodeller i Python. Därefter analyseras data för att identifiera normalfördelning, linjär korrelation och monotona relationer mellan variablerna med hjälp av korrelationsmatriser, QQ-plottningar och histogram. Baserat på denna analys valdes lämpliga korrelationsmått, såsom Pearson, Spearman och Kendall, för att utveckla modellen. Slutligen konstruerades och testades bayesianska nätverksmodellen för att studera inferens och dra slutsatser om fotbollsmatcherna, vilket ger insikter om komplexa beroenden mellan variablerna och möjliggör förbättrad strategisk planering och beslutsfattande inom sportanalys.

3.1 Beslut av metoder

I denna sektion utvärderas och jämförs olika tekniker och metoder för att identifiera den mest effektiva lösningen för examensarbetets behov.

3.1.1 Motivering till valet av MySQL

Valet av MySQL för detta projekt grundades på dess dokumenterade förmåga att hantera relationsdata och utföra komplexa SQL-frågor effektivt (26). MySQL är en av de mest använda relationsdatabashanterarna, känd för sin stabilitet, skalbarhet och säkerhet (27). Stabiliteten och skalbarheten är avgörande för att säkerställa att applikationen kan hantera en växande mängd data över tid utan att prestandan försämras. MySQL:s optimeringsmekanismer och stöd för ACID-egenskaper (Atomicity, Consistency, Isolation, Durability) gör det möjligt att upprätthålla dataintegritet och säkerhet, vilket är kritiskt för att säkerställa att data förblir korrekt och tillförlitlig genom alla operationer, något som är viktigt för att kunna fatta välgrundade beslut baserade på korrekt statistik.

MySQL kan också effektivt utföra komplexa SQL-frågor tack vare sina avancerade optimeringsalgoritmer och databasstrukturer (26). Denna kapacitet är särskilt viktig för applikationer som kräver snabb åtkomst och uppdatering av data, vilket är avgörande för att tränare och lagledare ska kunna få realtidsinsikter om spelarnas prestationer och därmed kunna göra snabba och informerade beslut.

Trots att dokumentorienterade databaser som MongoDB erbjuder högre flexibilitet och skalbarhet för hantering av stora och semi-strukturerade datamängder (8), prioriterades MySQL för dess förmåga att hantera relationsdata och utföra komplexa SQL-frågor effektivt (26, 27). Detta val säkerställer att applikationen kan hantera den nödvändiga datamängden och samtidigt erbjuda snabb och pålitlig dataåtkomst, vilket är avgörande för effektiv dataintegration och visualisering.

Genom att använda MySQL kan projektet dra nytta av dessa vetenskapligt dokumenterade fördelar, vilket inkluderar robust dataintegritet och hög prestanda. Framtida projekt kan överväga användning av MongoDB för dess anpassningsförmåga till dynamiska datastrukturer.

3.1.2 Användning av Neo4J för grafdatabasbehov

Valet av Neo4j för detta projekt grundades på dess förmåga att hantera komplexa nätverksstrukturer och effektivt utföra sökningar och analyser av grafdata (9). Neo4j erbjuder hög skalbarhet och stöd för ACID-egenskaper, vilket säkerställer dataintegritet och säkerhet, viktiga aspekter för korrekt datahantering. Dess användning av Cypher förbättrar effektiviteten vid sökning och hantering av stora datamängder, vilket är avgörande för snabb analys och visualisering av relationer mellan dataenheter.

Neo4j kan lagra data i nätverksbaserade grafer, vilket möjliggör effektiv lagring och sökning av komplexa relationer (9). Trots den högre kostnaden och inlärningskurvan för att använda Cypher, erbjuder Neo4j betydande fördelar vad gäller dataintegritet, prestanda och hantering av komplexa nätverksstrukturer, vilket gör den väl lämpad för projektets krav (9, 10).

3.2 Tillvägagångssätt för applikationsutveckling

3.2.1 Hantering av olika CSV format

I behandlingen av CSV-filer, som kan använda olika avgränsare såsom kommatecken (",") eller semikolon (";"), är det nödvändigt att implementera en mekanism som automatiskt detekterar och anpassar sig efter vilken avgränsare som används. Detta är avgörande för korrekt inläsning och bearbetning av data. CSV (Comma Separated Values) är ett filformat som lagrar tabulär data i ren text, där varje rad representerar en datapost och varje fält separeras av ett kommatecken. CSV-filens första rad innehåller vanligtvis kolumnrubriker, vilka måste extraheras och bevaras. Dessa rubriker fungerar som nycklar i en mappningsprocess där varje efterföljande rad i CSV-filen associeras med motsvarande kolumnrubrik, vilket säkerställer integriteten och strukturen av inläst data. Dessutom observerades att vissa filer använde citattecken (""), vilket indikerar att avgränsare inom citattecken inte ska betraktas som sådana (28). Denna detalj kräver noggrann hantering för att korrekt tolka och processa data inuti dessa citattecken.

I Figur 2 presenteras koden för metoden `replaceDelimiters`, som är utformad för att hantera olika avgränsare i CSV-filer på ett effektivt sätt. Metoden genomgår en sträng och använder en boolean för att spåra när den är inne i citattecken, vilket är nödvändigt för att korrekt tolka avgränsare. Om metoden stöter på ett semikolon utanför citattecken, ersätter den detta med ett kommatecken, vilket förenklar behandlingen av data genom att standardisera avgränsaren. Denna funktion är viktig för att korrekt läsa och bearbeta CSV-filer som använder olika avgränsare.

```
private String replaceDelimiters(String input) {
    boolean insideQuote = false;
    StringBuilder result = new StringBuilder();
    for (char c : input.toCharArray()) {
        if (c == '"') {
            insideQuote = !insideQuote; // Toggle the insideQuote state
        } else if (c == ';' && !insideQuote) {
            c = ','; // Replace semicolon with comma if not inside quotes
        }
        result.append(c);
    }
    return result.toString();
}
```

Figur 2: Kod för hantering av avgränsare för CSV filer

3.2.2 Unik identifierare för respektive dataset

I behandlingen av data från CSV-filer utvecklades en metod för att hantera unik identifiering av dataladdningar genom användning av `columnOrder`. Genom att extrahera och registrera kolumnordningen från den första raden i CSV-filen, tillsammans med skapandet av ett unikt identifierings-ID (UUID) för varje sats, kunde varje datamängd spåras effektivt. Detta UUID, tillsammans med metadata som `columnOrder`, registreras i systemet, vilket möjliggör noggrann spårning och hantering av uppladdade datasatser, och säkerställer att varje datauppsättning kan korreleras och verifieras över tid.

3.2.3 Utveckling av backend för koppling till MySQL databas

Applikationens backend-struktur, som är ansvarig för databehandling och hantering av användarbegäranden, utgörs av väldefinierade komponenter organiserade enligt Service-Repository-Controller-mönstret, vilket bidrar till en modulär och lättförståelig kodbas. Denna utveckling använder programmeringsspråket Java och inkluderar serverlogik, databashantering och integration med andra tjänster(2).

3.2.3.1 Controller-filerna

Filerna `MatchController` och `UserConfigController` är gränssnittet mellan applikationen och användarna, vilka tolkar inkommande HTTP-anrop och delegerar affärslogik-operationer till service-lagret. Exempelvis, `createMatch`-metoden i `MatchController` tar emot filuppladdningsförfrågningar. Användningen av multipart/form-data i denna kontext är essentiell, då det tillåter överföring av filer och textdata inom samma HTTP-förfrågan. Multipart innehåller data som är segmenterad i olika delar, vilket gör det möjligt för servern att korrekt hantera och extrahera filinnehåll samt andra fält som skickas av klienten. Detta protokoll är standard för filuppladdning och används på grund av dess förmåga att stödja komplexa datatyper på ett effektivt sätt.

I Figur 3 visas koden för `createMatch`-metoden i `MatchController`, som är utformad för att hantera filuppladdningar via HTTP. Metoden tar emot en fil och ett `matchnamn` som parametrar, vilket använder multipart/form-data för att tillåta samtidig överföring av filer och textdata. Vid framgång returneras ett svar med ett meddelande från `matchService`, och vid fel loggas felet och ett felmeddelande returneras. Denna metod är central för att möjliggöra effektiv datahantering och filuppladdning inom applikationen.

```
@PostMapping(value = "/uploadMatch", consumes = {"multipart/form-data"})
public ResponseEntity<?> createMatch(@RequestParam("file") MultipartFile file,
                                     @RequestParam("matchName") String matchName) {
    try {
        String response = matchService.uploadMatch(file, matchName);
        return ResponseEntity.ok(Map.of( k1: "message", response));
    } catch (Exception e) {
        logger.error("Error uploading match: ", e);
        return ResponseEntity.internalServerError().
            body(Map.of( k1: "error", v1: "Failed to upload the match."));
    }
}
```

Figur 3: Exempel på metod i controller-filen

3.2.3.2 Repository-filerna

I gränssnittslagret, som representeras av MatchRepository, har implementeringen av JpaRepository möjliggjort en reduktion av behovet att skriva egna databasfrågor. Detta gränssnitt tillhandahåller en uppsättning fördefinierade metoder för att hantera CRUD-operationer (Create, Read, Update, Delete), vilket minimerar komplexiteten i datalagerkoden. Några exempel på användandet av JpaRepository inkluderar metoder som findAll() för att hämta alla poster, save() för att spara eller uppdatera en post, deleteById() för att radera en post baserat på dess ID, och findById() för att hitta en specifik post.

3.2.3.3 Service-filerna

I Service-lagret hanteras affärslogiken, där implementeras metoder som tidigare nämnt i kapitel 3.1.1 och 3.1.2 men även metoder som hanterar uppladdning och inledande tolkning av CSV-filer, skapar en unik batchidentifierare (datakällaidentifierare) och ordnar datan innan den serialiseras till JSON för lagring.

I Figur 4 beskrivs parseCsv-metoden, som används inom service-lagret för att tolka och hantera CSV-filer. Metoden läser och konverterar filinnehåll till en lista av mappar där varje mapp representerar en rad i CSV-filen. Först detekterar metoden filens teckenkodning och använder UTF-8 som standard om ingen kodning upptäcks. Sedan används en BufferedReader för att läsa filens rader, där varje rad behandlas för att ersätta eventuella avvikande avgränsare innan raddatan delas upp enligt CSV-formatet och kartläggs mot dess respektive kolumnrubrik. Denna process säkerställer att datan blir korrekt strukturerad för vidare användning eller lagring.

```
private List<Map<String, String>> parseCsv(MultipartFile file) throws IOException {
    byte[] byteData = file.getBytes();
    String detectedEncoding = detectEncoding(byteData);
    if (detectedEncoding == null) {
        detectedEncoding = StandardCharsets.UTF_8.name(); // Default to UTF-8 if undetected
    }
    List<Map<String, String>> csvData = new ArrayList<>();
    try (BufferedReader reader = new BufferedReader(new InputStreamReader(file.getInputStream(), detectedEncoding))) {
        // Process the first line to get the headers
        String line = reader.readLine();
        if (line == null) {
            throw new IOException("CSV file is empty");
        }
        String processedLine = replaceDelimiters(line);
        String[] headers = new CSVParserBuilder().withSeparator(',').build().parseLine(processedLine);
        while ((line = reader.readLine()) != null) {
            processedLine = replaceDelimiters(line);
            String[] values = new CSVParserBuilder().withSeparator(',').build().parseLine(processedLine);
            Map<String, String> row = new LinkedHashMap<>();
            for (int i = 0; i < headers.length; i++) {
                // Map each value to its corresponding header
                String value = i < values.length ? values[i] : "";
                row.put(headers[i], value);
            }
            csvData.add(row);
        }
    }
}
```

Figur 4: Tolkning av csv-filer och mappar varje värde till dess motsvarande header

3.2.3.4 Entity-filerna

Entity-klasser är datastrukturer som återspeglar och synkroniserar med specifika databastabeller. Match-klassen, annoterad med @Entity, kopplas till match_entity-tabellen i databasen. Varje instans av Match motsvarar en rad i tabellen, med fält som id, matchName, och csvJson som mappas direkt

till kolumnerna. Användningen av `@Id` och `@GeneratedValue(strategy = GenerationType.IDENTITY)` innebär att id är en unikt genererad identifierare. Användningen av `@Column` anger attribut för fälten, exempelvis att `matchName` är obligatoriskt och `csvJson` lagras som JSON.

	id	csv_json	match_name
▶	85	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "...	AIK - Häcken
	86	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "", "...	AIK - Norrköping
	87	[{"data": [{"Player": "██████████", "Tactic": "2", "Technic": "...	Brommapojkarna - AIK
	88	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "...	Djurgården - AIK
	91	[{"data": [{"Player": "██████████", "Tactic": "3", "Technic": "3...}	Örebro - AIK
	92	[{"data": [{"Player": "██████████", "Tactic": "3", "Technic": "...	Malmö - AIK
	93	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "", "...	Häcken - AIK
	94	[{"data": [{"fouls": "0", "shots": "0", "rating": "6.6133", "sno": "2", "...	Hammarby - AIK
	95	[{"data": [{"Player": "██████████", "Tactic": "3", "Technic": "...	Halmstad - AIK
	96	[{"data": [{"Tactic": "3", "Technic": "3", "Physique": "3", "Position": "...	Norrköping - AIK
	97	[{"data": [{"Player": "██████████", "Tactic": "3", "Technic": "2", "Ph...	Östers - AIK
	98	[{"data": [{"fouls": "1", "shots": "0", "rating": "6.97877", "sno": "2", "...	AIK - Östers
	99	[{"data": [{"Player": "██████████", "Tactic": "2", "Technic": "3...}	AIK - GAIS
	100	[{"data": [{"Player": "██████████", "Tactic": "3", "Technic": "2", "...	AIK - Västerås
	105	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "", "...	AIK - Djurgården
	111	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "", "...	AIK - Halmstad
	113	[{"data": [{"Player": "██████████", "Tactic": "3", "Technic": "3...}	AIK - Brommapojkarna
	114	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "...	AIK - Malmö
	115	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "", "Physi...	AIK - Hammarby
	116	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "", "Physi...	GAIS - AIK
	117	[{"data": [{"Player": "██████████", "Tactic": "", "Technic": "", "Physi...	Västerås - AIK
*	NULL	NULL	NULL

Figur 5: Persistenta lagringen av alla data i MySQL

3.2.3.5 Konfiguration av databasanslutning

När man konfigurerar databasanslutningen i en Spring Boot-applikation, görs detta genom att specificera viktiga parametrar i `application.properties`-filen. Här anges JDBC-URL:n (Java Database Connectivity) för att peka mot den lokala databasservern, tillsammans med användarnamn och lösenord för autentisering. Ytterligare konfigurationer inkluderar Hibernate-inställningar såsom uppdateringsmetod för databasschemat, SQL-dialekten som matchar databasversionen, och om SQL-kommandon ska visas i loggen för felsökning. Detaljer om hantering av multipart-filer definieras också, inklusive aktivering av uppladdningsfunktionen och storleksbegränsningar för filer och förfrågningar.

3.2.4 Utveckling av backend för koppling till Neo4J databas

För att utveckla backend-strukturen kopplad till en Neo4j-databas användes samma Service-Repository-Controller-mönster som för MySQL, med anpassningar för dynamisk hantering av parametrar och entitetsrelationer, även konfiguration för databasanslutningen var likartade. Trots att grundarkitekturen är densamma mellan MySQL och Neo4j, krävs anpassningar i service- och entitetslagren på grund av skillnader i datalagringsmetoder. Sådana anpassningar inkluderar specifik logik för att effektivt hantera de dynamiska förfrågningarna som är karakteristiska för grafdatabaser. Denna utveckling använder programmeringsspråket Java.

3.2.4.1 Service-filerna

I service-klassen för hantering av spelardata i en Neo4j-databas, inkluderar metoden `parseCsv` funktionalitet för att bearbeta och omvandla innehållet i en CSV-fil till en lista av kartor (`Map<String, Object>`), vilket underlättar vidare datahantering. Metoden `savePlayerWithMatchNameAndProperties` använder Cypher-språket för att sammanfoga samt uppdatera spelarinformation i databasen och

hanterar dynamiska attribut genom flexibla frågekonstruktioner. Metoden `getAllPlayers` extraherar alla spelarobjekt från databasen, vilket ger en översikt över befintliga data, och konverterar denna information till objekt som kan hanteras vidare inom applikationen.

3.2.4.2 *Entity-filerna*

I Entity komponenten används en `Player`-klass, som är annoterad med `@Node`, representeras en spelare i en Neo4j-databas. Klassen innehåller flera attribut: `id`, som är en unikt genererad identifierare annoterad med `@Id` och `@GeneratedValue`; `uuid`, ett unikt UUID som initialiseras vid objektets skapande; `matchName`, som lagrar matchens namn; samt `properties`, en karta som kan hålla ett dynamiskt set av egenskaper associerade med spelaren. Denna struktur underlättar flexibel datahantering och möjliggör dynamisk interaktion med graf-databasen genom att objektets egenskaper lätt kan expanderas eller modifieras.

3.2.5 Utveckling av frontend-applikationen

För utvecklingen av frontend-applikationen, vilket är den del av en webbapplikation som användarna ser och interagerar med (29), implementeras en komponentbaserad struktur som delar upp applikationens logik och presentation i skilda komponenter, tjänster och stilar, för att underlätta underhåll och skalbarhet. I `components`-mappen skapades återanvändbara komponenter såsom `Container.js` och `DataChart.js`, vilka används för att bygga upp användargränssnittet. Tjänsterna i `services`-mappen, som `apiservices.js`, hanterar alla API-anrop. CSS-filerna i `styles`-mappen definierar applikationens stil och layout. Slutligen, i `views`-mappen, samsas de olika vyerna som `Dashboard.jsx` och `AddGameSet.js`, vilka representerar de sidor användaren navigerar mellan. Denna utveckling använder programmeringsspråket JavaScript.

3.2.5.1 *Component-filerna*

För `component`-filerna används två primära filer, `Container.Js` och `DataChart.Js`. `Container` filen har i uppgift att behålla i en liten ruta en del av innehållet från uppladdning av filer (vilket kommer tas upp i senare del-kapitel). Att skapa `DataChart`-komponenten i React innebär att implementera en flexibel visualisering av data genom både stapel- och cirkeldiagram beroende på användarinteraktion. Tillståndshanterare initieras för att lagra dataserier medan `useEffect`-kroken aktiveras vid ändringar i valda matcher eller spelare. Denna effekt hanterar normalisering och matchning av spelarstatistik mot valda attribut, och inkluderar dynamisk färgtilldelning för visualisering. Dessutom utförs noggrann sökning och normalisering av spelarnamn från CSV-filer för att korrekt identifiera och hantera namnmatchningar. Denna process säkerställer att rätt data kopplas till rätt spelare och förhindrar datainkonsekvenser, vilket är kritiskt för att presentera korrekt information i diagrammen. Slutligen renderas diagrammen baserat på användarval och konfigurationer för `Chart.js`, och hela komponenten exporteras för återanvändning.

3.2.5.2 *Services-filen*

Att skapa en service-fil som `ApiService` i en JavaScript-applikation syftar till att centralt hantera alla REST API-kommunikationer med servern. En REST API (Representational State Transfer API) är en metod för att bygga webbaserade tjänster som använder HTTP-protokoll för att utföra CRUD-operationer (Create, Read, Update, Delete) över nätverk (30). Klassen `ApiService` definierar metoder för olika REST API-interaktioner som att skapa matcher, hämta och uppdatera data, samt hantera filuppladdningar med `FormData` där webbläsaren själv sätter rätt 'Content-Type'. Varje metod använder

fetch för att skicka förfrågningar och hanterar responsen systematiskt. Felhantering ingår där varje svars status kontrolleras och ett felmeddelande genereras om något går fel, vilket försäkras robusthet i datatillgång och manipulation över applikationens gränssnitt.

3.2.5.3 *Styles-filerna*

I avsnittet för utveckling av CSS-stilar hanteras applikationens visuella design och layout. I styles-mappen struktureras CSS-filerna för att ge detaljerad stilisering av komponenter som visas i olika vyer av applikationen. Stilbladen definierar flexibla layouter med hjälp av flexbox-modellen, responsiva designegenskaper för att stödja olika enheter, och visuella effekter som övergångar och animationer för att förbättra användarinteraktionen. Stilarna säkerställer en konsistent användarupplevelse över hela applikationen genom att standardisera utseendet på element som knappar, inmatningsfält och navigationskomponenter.

3.2.5.4 *Views-filerna*

View-filerna i en React-applikation är ansvariga för att presentera användargränssnittet och hantera interaktioner med användaren. De kombinerar logik och presentation genom att använda komponenter, API-anrop och tillståndshantering för att skapa dynamiska och responsiva vyer som förbättrar användarupplevelsen. Exempel på detta är två filer AddGameSet.js samt Dashboard.js som hanterar olika funktionaliteter.

AddGameSet hanterar uppladdning och tolkning av CSV-filer med hjälp av Papa.parse och lagrar data tillståndsmässigt. Användaren kan ladda upp filer, och komponenten hanterar dynamiskt tillägg av nya "containers" vid behov för att hantera flera filuppladdningar samtidigt. Detta gör det möjligt för användare att kontinuerligt ladda upp och visa CSV-data inom samma session.

Dashboard-vyn låter användare välja och visa detaljerad data om specifika matcher. Den hämtar matchinformation från en server via apiService, och tillåter dynamiska val av vilka data som ska visas genom filtrering baserat på användarens val. Användaren kan interagera med data genom att välja olika visualiseringar, som diagram, och manipulera datavisningar baserat på specifika parametrar som maximala värden eller specifika spelare. Detta görs med hjälp av integrationen av javascript-biblioteket chartjs.

3.2.6 *Datainsamling*

Inom ramen för detta examensarbete har kvalitativa data samlats in från tre ledande plattformar inom fotbollsanalys: Soccerlab, Eyeball, och Playmaker. Varje plattform erbjuder unika funktioner och datatillgänglighet som har varit avgörande för att kunna utföra en omfattande analys av ungdomsfotbollens talangutveckling.

3.2.6.1 *Soccerlab*

Soccerlab tillhandahåller omfattande data som kräver manuell överföring till analyserbara format. Processen innefattade ett arbete där data först överfördes till Excel-ark för att sedan konverteras till CSV-filer. Detta manuella steg var nödvändigt för att denna plattform inte erbjöd något sätt att exportera all data direkt.

3.2.6.2 Eyeball och Playmaker

Till skillnad från Soccerlab, erbjuder Eyeball och Playmaker direkt export av data till CSV-format, vilket underlättat snabbare och mer effektiv datainsamling och integration. Denna funktionalitet har möjliggjort en smidigare hantering av stora datamängder och minimerat risken för dataförlust eller fel som kan uppstå vid manuell dataöverföring.

3.2.6.3 Analys och hantering av data

Den insamlade datan från de tre plattformarna har integrerats i ett enhetligt format som möjliggör jämförelser och analyser över plattformsgränserna. Denna metodik säkerställer att studiens resultat är baserade på en bred och representativ datamängd, vilket förstärker tillförlitligheten och relevansen i de slutsatser som dragits.

3.2.7 Utmaningar och strategier för visualisering av data i diagram

Efter att framtagningen av all spelarstatistik från plattformarna (Soccerlab, Eyeball och Playmaker) var lagrad i en centraliserad databas och kunde hämtas av frontend med hjälp av REST api, så behövdes visualiseringen av statistiken bestämmas. Applikationen skulle vara dynamisk, det innebar att användaren skulle kunna ladda upp csv-filer utan restriktion på formatet och vilka parametrar som fick användas. Detta krävde en flexibel lösning för att visualisera data från specifika kolumner utan att behöva programmera för specifika datatyper i förväg. Under en demonstration med lagledaren från AIK:s ungdomsfotbollslag diskuterades olika lösningar, och det beslutades gemensamt att det mest effektiva tillvägagångssättet skulle vara att låta användaren själv ange vilka parametrar som skulle jämföras. Detta val motiverades av komplexiteten i att dynamiskt programmera en logik som automatiskt kunde identifiera och jämföra relevanta kolumner från olika dataset.

Ett motargument som övervägdes var risken att användare kanske inte alltid skulle veta vilka kolumner som var mest relevanta att jämföra, vilket kunde leda till mindre meningsfulla eller missvisande visualiseringar. Trots detta bedömdes användarstyrningen som den mest flexibla och användarvänliga lösningen, särskilt då den möjliggjorde anpassningar baserade på användarens specifika kunskap om de underliggande data. För att göra parametrarna i diagrammen jämförbara, och eftersom olika plattformar använde sig av olika förbestämda skalsystem för betygssättning, där Soccerlab använder en skala från ett till fyra, Eyeball från ett till tio och Playmaker från ett till fem, beslutades det att låta användarna själva ange ett maxvärde för varje parameter. Efter detta skulle datan utvärderas procentuellt, vilket gjorde det möjligt att skapa jämförbara visualiseringar över plattformsgränserna.

The image shows a user interface for configuring data batches. It consists of three vertically stacked sections, each for a different batch:

- Batch 1:** The dropdown 'Select Header for Batch 1:' is set to 'Total Score'. The 'Max Value (optional):' input field contains the number '4'. A blue 'Save Max Value' button is to the right.
- Batch 2:** The dropdown 'Select Header for Batch 2:' is set to 'rating'. The 'Max Value (optional):' input field contains the number '10'. A blue 'Save Max Value' button is to the right.
- Batch 3:** The dropdown 'Select Header for Batch 3:' is set to 'Playmaker Rank'. The 'Max Value (optional):' input field contains the number '5'. A blue 'Save Max Value' button is to the right.

Figur 6: Gränssnitt som tillåter användare att välja parametrar samt om önskas, ange max värden

3.2.7.1 Verifiering och validering

För att säkerställa att applikationen uppfyller sina mål genomfördes både användartester och interna tester för att verifiera och validera dess förmåga att hantera och visualisera data på ett korrekt sätt.

Funktionstester av datavisualisering hade som syfte att säkerställa att applikationen korrekt hanterar och visualiserar data från olika källor. Användare laddade upp CSV-filer från de olika statistikplattformarna Soccerlab, Eyeball och Playmaker, och specificerade parametrar för jämförelse. Stegen inkluderade att ladda upp CSV-filer med olika dataformat, ange parametrar för visualisering samt generera diagram och granska justeringar baserade på användarens inställningar för maxvärden.

Validering av användarvänlighet syftade till att utvärdera användarvänlighet och effektiviteten av applikationen. Metoden innefattade att lagledare från AIK:s ungdomsfotbollslag testade en första version av applikationen medan författaren genomförde interna tester på slutprodukten. Stegen som lagledaren tog var att ladda upp data och ställa in parametrar, generera diagram och analysera data samt ge feedback om användarupplevelsen. De interna testerna utfördes genom systematiska enhetstester och integrationstester för att verifiera funktionaliteten i varje komponent och deras samspel. Specifikt testades applikationens förmåga att snabbt och korrekt läsa in olika CSV-format, hantera felaktiga dataingångar utan att krascha, och upprätthålla prestanda under hög belastning. Responsiviteten testades också genom att simulera olika användarscenarion för att garantera att applikationen reagerade adekvat på användarinteraktioner, särskilt vid parameterinställningar och datavisualisering.

Kontroll av datainkonsistenser hade som syfte att identifiera och förstå datainkonsistenser. Metoden använde data från olika källor för att visualisera inkonsekvenser. Stegen inkluderade att ladda upp data från olika källor, generera visualiseringar som presenterar data på ett sammanhållet sätt samt att användarna identifierar och förstår datainkonsistenser genom visualiseringarna.

Genom denna metodik för verifierings- och valideringstester säkerställdes att applikationen både tekniskt och praktiskt uppfyllde sina mål att förbättra dataintegration och visualisering för tränare och ledare inom ungdomsfotboll.

3.3 Tillvägagångssätt för dataanalys och modellering

För att skapa en tillförlitlig bayesiansk nätverksmodell är det viktigt att först analysera datan för att förstå dess underliggande fördelningar och relationer. Bayesianska nätverksmodeller är särskilt användbara för dataanalyser på grund av deras förmåga att hantera osäkerheter och komplexa beroenden mellan variabler. Dessa modeller representerar sannolikhetsfördelningar och beroenden i form av riktade acykliska grafer, där Bayes teorem används för att kontinuerligt uppdatera modellen med ny information. Denna flexibilitet och anpassningsbarhet gör bayesianska nätverksmodeller kraftfulla för inferens i situationer med osäker eller bristfällig information (17).

En viktig fördel med Bayesianska nätverk är deras lämplighet för små datasets och komplexa samband. Då datasetet för denna studie förväntas vara litet och sambanden mellan variablerna komplexa, är Bayesiansk nätverksanalys särskilt fördelaktig eftersom metoden kan integrera tidigare kunskap och expertbedömningar för att förbättra modellens noggrannhet (18).

Detta tillvägagångssätt involverar att använda histogram, QQ-plottning och regressionsplottning för att bedöma normalfördelningen av variablerna samt att identifiera monotona relationer, outliers och

icke-parametriska relationer. Korrelationsmatriser används för att bedöma om relationerna mellan variablerna är linjära. Baserat på denna föranalys väljs det mest lämpliga korrelationsmåttet för att bygga modellen. Nedan beskrivs dessa steg i detalj.

3.3.1 Installation av Python och nödvändiga paket

För att genomföra den statistiska dataanalysen på fotbollsmatcher användes Python, ett kraftfullt programmeringsspråk populärt inom dataanalys och maskininlärning. Python installerades från den officiella webbplatsen medan de nödvändiga paketen installerades med hjälp av pakethanteraren pip. De specifika paketen som användes i detta arbete inkluderar:

- NumPy och Pandas för datahantering och manipulation.
- Matplotlib och Seaborn för att skapa visualiseringar såsom histogram.
- SciPy för statistiska analyser, inklusive QQ-plottning och korrelationsmatriser.
- Pgmpy för att bygga och analysera bayesianska nätverksmodeller.

Installationen av dessa paket gjordes med följande kommando: "pip install numpy pandas matplotlib seaborn scipy pgmpy". Dessa paket var nödvändiga för att utföra den omfattande dataanalysen och bygga bayesianska nätverksmodellen, vilket lade grunden för en detaljerad och korrekt analys av fotbollsmatcherna.

3.3.2 Analysera normalfördelning med Histogram och QQ-plottning

För att undersöka om variablerna i datan var normalfördelade skapades histogram och QQ-plottningar. I Figur 7 presenteras en del av koden som används för att förbereda data för analys av normalfördelning genom histogram och QQ-plottning. Koden inleds med att normalisera positionsvärden genom att omvandla text till versaler. Sedan identifieras numeriska kolumner baserade på datatyperna float64, int64, och float32. För att säkerställa att endast kolumner med tillräcklig varians inkluderas, filtreras data baserat på en förutbestämd tröskel för låg varians. Slutligen rensas datamängden från rader som innehåller NaN-värden eller oändliga värden för att undvika beräkningsfel i den statistiska analysen.

```
# Normalisera positionvärden
data['Position'] = data['Position'].str.upper()

# Filtrera ut endast numeriska kolumner
numeric_data = data.select_dtypes(include=['float64', 'int64', 'float32'])

# Filtrera bort kolumner med låg varians
low_variance_threshold = 0.01
numeric_data = numeric_data.loc[:, numeric_data.var() > low_variance_threshold]
filtered_numeric_columns = numeric_data.columns.tolist()

# Ta bort rader med NaN eller oändliga värden
numeric_data = numeric_data.replace([np.inf, -np.inf], np.nan).dropna()
```

Figur 7: Kod för förberedelsen av data

Därefter skapades både histogram och QQ-plottning för alla numeriska kolumner. Histogrammen hjälper till att visuellt kontrollera om en variabel ser ut att vara normalfördelad genom att visa frekvensfördelningen av dess värden. QQ-plottningen används för att bedöma om en variabel följer en

specifik fördelning, såsom normalfördelning, genom att jämföra kvantilerna av variabelns fördelning med kvantilerna av en normalfördelning.

I Figur 8 visas den fortsatta koden där varje numerisk kolumn genererar ett histogram och en QQ-plottning i ett organiserat rutnät med flera paneler. För varje kolumn visas först ett histogram med en överlagd kärntäthetskurva för att illustrera frekvensfördelningen och dess närhet till en normalfördelning. Direkt efter följer en QQ-plottning för samma kolumn, där datakvantilerna jämförs med de teoretiska kvantilerna av en normalfördelning.

```
# Histogram och QQ-plots
n_cols = 4 # Antal kolumner i subplot grid
n_rows = len(filtered_numeric_columns) * 2 // n_cols + (len(filtered_numeric_columns) * 2 % n_cols > 0)
plt.figure(figsize=(n_cols*5, n_rows*5))
for i, col in enumerate(filtered_numeric_columns):
    plt.subplot(n_rows, n_cols, i + 1)
    sns.histplot(numeric_data[col], kde=True)
    plt.title(f'Histogram of {col}')
    plt.subplot(n_rows, n_cols, i + 1 + len(filtered_numeric_columns))
    stats.probplot(numeric_data[col], dist="norm", plot=plt)
    plt.title(f'QQ-plot of {col}')
plt.tight_layout()
plt.show()
```

Figur 8: Skapandet av histogram och QQ-plottning för alla numeriska kolumner

3.3.3 Analysera korrelationsmatrisen

En korrelationsmatris skapades för att undersöka de linjära och monotona relationerna mellan variablerna. Detta är viktigt för att förstå hur variablerna samvarierar, vilket kan påverka modelleringen i en bayesiansk nätverksmodell. För att få en omfattande bild av relationerna mellan variablerna användes tre olika korrelationsmått: Pearson, Spearman och Kendall.

3.3.3.1 Val av korrelationsmetoder

- **Pearson-korrelation:** Är en statistisk metod som mäter graden av linjär association mellan två kontinuerliga variabler. Den används för att kvantifiera hur starkt två variabler är relaterade till varandra. För att använda Pearson-korrelationen bör båda variablerna vara normalfördelade, och det antas att det finns en linjär relation mellan dem (1).
- **Spearman-korrelation:** Är en icke-parametrisk metod som mäter den rangordnade associationen mellan två variabler. Istället för att fokusera på de exakta värdena använder Spearman rankningarna av variablerna. Den är användbar när data inte är normalfördelad eller när vi har ordinalskalade variabler. Spearman-korrelationen är mindre känslig för extrema värden och fungerar bra även när associationen inte är strikt monoton (1).
- **Kendall's Tau:** Är en annan icke-parametrisk metod för att mäta rangordnad association. Den liknar Spearman-korrelationen och används när vi har ordinalskalade variabler eller när data inte är normalfördelad. Kendall's tau är robust mot utliggare (en: outliers) och fungerar bra även när associationen inte är strikt monoton (1).

För varje korrelationsmått togs en separat korrelationsmatris fram. Pearson's korrelationsmatris användes för att identifiera linjära relationer mellan variablerna, medan Spearman's och Kendall's kor-

relationsmatriser användes för att identifiera monotona relationer. Varje korrelationsmatris analyserades för att bedöma hur väl den passade med de tidigare analyserna av normalfördelningen och relationstyperna mellan variablerna.

Figur 9 visar koden som används för att beräkna och visualisera korrelationsmatriser med dessa metoder. För varje metod genereras en matris som sedan plottas som en heatmap för visuell representation. Denna visualisering använder seaborn för att skapa en detaljerad heatmap där korrelationerna presenteras med färgkodning, annoteringar och justerbar färgskala, vilket ger en klar överblick över relationerna mellan variablerna.

Genom att jämföra dessa korrelationsmatriser kunde den mest lämpliga korrelationsmetoden väljas för den bayesiansk nätverksmodell som skulle konstrueras. Detta steg var avgörande för att säkerställa att modellen fångade de viktigaste relationerna mellan variablerna och kunde utföra tillförlitlig inferens baserat på data.

```
# Beräkna korrelationsmatrisen med olika metoder
methods = ['pearson', 'spearman', 'kendall']

for method in methods:
    print(f'\nCorrelation matrix using {method} method:')
    correlation_matrix = numeric_data.corr(method=method)

    # Skapa korrelationsplot
    plt.figure(figsize=(30, 15))
    sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt='.2f',
                linewidths=.5, cbar_kws={"shrink": .8}, vmin=-1, vmax=1)
    plt.title(f'Correlation Matrix ({method.capitalize()})', fontsize=20)
    plt.xticks(rotation=45, ha='right', fontsize=12)
    plt.yticks(fontsize=12)
    plt.show()
```

Figur 9: Skapandet av korrelationsmatris med metoderna pearson, spearman och kendall

3.3.4 Analysera relationer med regressionsplottning

För att ytterligare undersöka relationerna mellan variablerna och motivera valet av korrelationsmått skapades regressionsplottning. Dessa plottningar gav en visuell representation av relationerna och hjälpte till att identifiera både linjära och icke-linjära samband samt eventuella outliers. Denna process visualiseras i Figur 10, där kod används för att skapa en serie av regressionsplottar för varje par av numeriska kolumner som uppvisar hög korrelation.

I koden för Figur 10, skapas en plottning för varje kombination av numeriska kolumner med hög korrelation. För varje par används scatterplot för att visa datapunkterna, med positionen färgkodad för att ge ytterligare insikter om hur olika kategorier distribueras. Därefter läggs en regressionslinje till varje plottning med regplot, där linjen är markerad i rött för tydlig synlighet.

```
# Skapa en plot för varje kombination av numeriska kolumner med hög korrelation
for i, (x, y) in enumerate(high_correlation_pairs):
    sns.regplot(x=x, y=y, data=data, ax=axes[i], scatter_kws={'alpha':0.5}, line_kws={'color':'red'})
    sns.scatterplot(x=x, y=y, hue='Position', data=data, ax=axes[i], legend=True, alpha=0.6)
    axes[i].set_title(f'Regressionsplot of {x} vs {y}')
plt.tight_layout()
plt.show()
```

Figur 10: Skapandet av regressionsplottningar för samtliga par med hög korrelation

3.3.5 Utveckling av bayesiansk nätverksmodell

Efter att ha analyserat och kombinerat all data från alla plattformar samt valt det mest lämpliga korrelationsmättet, byggdes en bayesiansk nätverksmodell med hjälp av paketet pgmpy, som visas i Figur 11. Koden inleds med att välja en korrelationsmetod baserad på tidigare analyser och använder denna för att beräkna en korrelationsmatris. Starka korrelationer identifieras, och en begränsning till de 400 starkaste paren genomförs för att definiera nätverkets struktur. Nätverket tränas sedan med Maximum Likelihood Estimation och visualiseras med hjälp av NetworkX och Graphviz, där varje kant är viktad med den motsvarande korrelationskoefficienten.

```
correlation_method = 'x' #ändras baserat på resultatet från föranalysen
# Beräkna korrelationsmatris baserat på vald metod
correlation_matrix = data[filtered_numeric_columns].corr(method=correlation_method)
# Identifiera starka korrelationer och begränsa antalet par
strong_corr_pairs = [(x, y) for x, y in combinations(filtered_numeric_columns, 2) if abs(correlation_matrix.loc[x, y]) > 0.1]
strong_corr_pairs = strong_corr_pairs[:400] # Begränsa till de 400 starkaste paren
# Skapa Bayesian Network-struktur
model = BayesianNetwork(strong_corr_pairs)
# Träna modellen med Maximum Likelihood Estimation
try:
    model.fit(data, estimator=MaximumLikelihoodEstimator)
except Exception as e:
    print(f"Fel vid träning av Bayesian Network-modellen: {e}")
# Visualisera nätverket med detaljerad information
G = nx.DiGraph()
G.add_edges_from(model.edges())
edge_labels = {(x, y): f'{correlation_matrix.loc[x, y]:.2f}' for x, y in strong_corr_pairs}
# Rita grafen
plt.figure(figsize=(25, 20))
pos = graphviz_layout(G, prog='dot')
nx.draw(G, pos, with_labels=True, node_size=3000, node_color='lightblue', font_size=10, font_weight='bold', edge_color='gray', arrows=True)
nx.draw_networkx_edge_labels(G, pos, edge_labels=edge_labels, font_color='red')
plt.title('Bayesian Network Structure with Detailed Edge Weights')
plt.show() # Visa grafen
```

Figur 11: Skapandet av bayesiansk nätverksmodell samt illustration av grafen

I den angivna koden för Figur 12 skapas en funktion för att utföra bayesiansk inferens baserat på starka korrelationspar och ett standardbevis för variabeln "Played Minute". Först initialiseras variabeln för att representera spelare som spelat hela matchen. Därefter loopar funktionen genom varje par i listan av starka korrelationer. För varje par kontrolleras om paret innehåller den undersökta variabeln och om så är fallet, läggs den andra variabeln i paret till som ytterligare bevis.

```
from tabulate import tabulate
def perform_inference(query):
    print(f"Performing inference for query: {query}")
    try:
        infer = VariableElimination(model)
        variable_importance = {}
        # Loop över varje variabel i strong_corr_pairs
        for var1, var2 in strong_corr_pairs:
            if var1 == 'Played Minute' and var2 == query:
                continue # Hoppa över om paret är (Played Minute, query)

            evidence = {'Played Minute': 90} # Återställ bevis för varje par

            # Välj vilken variabel som ska läggas till som bevis (antingen var1 eller var2)
            if var1 == 'Played Minute' and var2 != query:
                evidence[var2] = data[var2].mode().iloc[0] if data[var2].mode().iloc[0] != 0 else data[var2].value_counts().index[1]
                variable = var2
            elif var2 == 'Played Minute' and var1 != query:
                evidence[var1] = data[var1].mode().iloc[0] if data[var1].mode().iloc[0] != 0 else data[var1].value_counts().index[1]
                variable = var1
            else:
                continue
            try:
                result_without_evidence = infer.query(variables=[query])
                result_with_evidence = infer.query(variables=[query], evidence=evidence)
                if isinstance(result_with_evidence, DiscreteFactor):
                    initial_prob = result_without_evidence.values.max()
                    new_prob = result_with_evidence.values.max()
                    importance = new_prob - initial_prob
                    variable_importance[variable] = importance
            except Exception as e:
                print(f"Error querying {query} with evidence variables Played Minute = 90, {var1}, {var2}: {e}")
        # Sortera variablerna efter deras viktighet och välj de tre viktigaste
        sorted_variables = sorted(variable_importance.items(), key=lambda item: item[1], reverse=True)[:3]
        df = pd.DataFrame(sorted_variables, columns=["Variable", "Importance"])
        print(f"The three most important variables for query {query} are:")
        print(tabulate(df, headers="keys", tablefmt="grid"))
    except Exception as e:
        print(f"Error performing inference for query {query}: {e}")
```

Figur 12: Funktion som tillåter användare att specificera vilken variabel som man vill utföra inferens på

För att kvantifiera påverkan av en variabel beräknas skillnaden mellan sannolikheten för den undersökta variabeln med och utan den extra evidensvariabeln. Om sannolikheten för den undersökta variabeln förändras signifikant när en ny variabel introduceras som bevis, indikerar detta att variabeln har ett starkt inflytande (20). Denna metod används för att förstå hur olika faktorer bidrar till ett utfall och för att prioritera vilka variabler som är mest kritiska att övervaka eller manipulera i en given situation.

I detta sammanhang används ordet viktighet (importance) för att beskriva denna påverkan. Viktigheten kvantifieras genom att mäta förändringen i sannolikhet för den undersökta variabeln när en annan variabel används som bevis. En hög viktighet indikerar att den extra variabeln har en stark påverkan på sannolikheten för den undersökta variabeln. Detta baseras på forskning som beskriver hur bayesianska nätverk kan användas för att uppdatera sannolikhetsfördelningar baserat på observerade data och evidens. Ding (19) förklarar hur probabilistisk inferens i bayesianska nätverk möjliggör att besvara komplexa frågor genom att propagera information genom nätverket och uppdatera sannolikhetsfördelningarna.

För att analysera viktigheten i bayesianska nätverk följs en strukturerad metodik. Initialiseringen av inferensprocessen görs genom att använda en metod för probabilistisk inferens, vilket möjliggör beräkning av den posteriora sannolikheten för variabler givet bevis. Bevisuppsättning och iteration sker genom att för varje korrelationspar tilldela det mest frekventa värdet för den andra variabeln i paret, förutom "Played Minute" som redan är satt till 90 minuter. Detta tillvägagångssätt tillåter effektiv bedömning av varje pars påverkan på den undersökta variabeln.

Inferens utförs därefter genom att beräkna sannolikhetsfördelningen för den undersökta variabeln både med och utan det extra beviset. Skillnaden i sannolikhet mellan dessa två tillstånd kvantifierar variabelns viktighet. Efter beräkningen av viktigheten för varje variabel sorteras dessa variabler och de tre viktigaste identifieras. Resultaten presenteras i en tabell för att tydligt visa vilka variabler som har störst påverkan.

Analyserna kan avslöja vilka variabler som har störst inflytande på spelarens prestationer och rating. Genom att förstå vilka faktorer som påverkar utfallet mest kan tränare och analytiker prioritera vilka områden som bör fokuseras på för att förbättra spelares prestationer. Viktighetsanalysen kan också hjälpa till att identifiera dolda samband mellan variabler som inte är uppenbara vid första anblicken.

4 Resultat


Detta kapitel presenterar resultaten från de analyser som utförts för att utforska i vilken utsträckning datainkonsistenserna på spelarstatistiken förekommer inom ungdomsfotbollens lag. Data som samlats in genom att både utföra manuell dataöverföring samt exportering av csv-filer från plattformarna har utvärderats för att visualisera data inkonsistenserna. Denna visualisering förtydligar hur datan skiljer sig åt för varje spelare under varje match samt ger ett genomsnittligt värde för varje spelare under alla spelade matcher. Nedan följer en detaljerad redogörelse för de kvantitativa resultaten som framkommit under studiens gång.

4.1 Representation av datan

Detta avsnitt visar de statistiska resultaten som har visualiserats genom en rad diagram, tabeller och nätverksbaserade grafer. Varje grafisk representation har använts för att illustrera specifika aspekter av insamlade data, inklusive spelarprestationer och dynamiken i deras interaktioner över säsongen. Presentationen i detta kapitel omfattar en detaljerad visuell översikt av de kvantitativa resultaten som erhållits från studien.

4.1.1 Exempel på diagram från enskilda matcher för vald parameter


I kommande exempel presenteras ett diagram som representerar statistiska resultat för 'Spelare 1' samlade från de tre olika plattformarna (datakällor, refererat till som '*batches*'), detta diagram visar en tydlig skillnad i de rapporterade resultaten för betygsättningen för varje batch: Batch 1 visar ett resultat på 69.75 enheter, Batch 2 pekar på en lägre siffra, nämligen 67.5 enheter, medan Batch 3 visar ett avsevärt lägre resultat på 40 enheter. Observationerna från diagrammet indikerar att det finns en betydande variation i de insamlade datan för 'Spelare 1' över olika batches, denna variation kan tyda på potentiella inkonsistenser i datan eller skillnader i metoder för datainsamling och -analys använda från varje plattform.



Figur 13: Diagram för enskilda matcher med y-axeln som visar procentuell betygsättning från olika datakällor

4.1.2 Exempel på diagram från samtliga matcher för vald parameter

I det följande exemplet presenteras ett diagram som visar prestationerna för 'Spelare 5', baserat på data insamlad från upp till 21 möjliga matcher. Denna siffra, 21, representerar det totala antalet matcher som laddats upp till databasen och fungerar som ett referensvärde för att visa hur omfattande datainsamlingen kan vara. Det är viktigt att notera att den faktiska datamängden för varje spelare varierar beroende på antalet matcher de deltagit i, vilket kan vara färre än 21. Dessutom kan mängden data som rapporterats från olika plattformar variera. För 'Spelare 5' har följande resultat rapporterats: från Soccerlab, baserat på 4 matcher, är det genomsnittliga totala poängen 56.25 procentenheter; från Eyeball, baserat på 5 matcher, är den genomsnittliga ratingen 70.22 procentenheter; och från Playmaker, baserat på 7 matcher, är den genomsnittliga Playmaker Rank 42.86 procentenheter.



Figur 14: Diagram för visning av samtliga matcher med y-axeln som visar procentuell betygsättning från olika datakällor

4.1.3 Exempel på tabell för enskild match

Detta exempel visar hur kvantitativa data från en typisk match presenteras i tabell 1 nedan, där detaljerade spelarprestationer från matchen mellan Örebro och AIK sammanfattas. Informationen omfattar spelarnas positioner, spelade minuter och poäng för teknik, taktik, mentalitet och fysik. Tabellen ger en överblick över varje spelares individuella bidrag samt identifierar områden för potentiell förbättring. Data visar att de flesta startspelare spelade hela matchen, medan ersättare som kom in hade varierande speltider.


Tabell 1: Exempel på tabell med data från SoccerLab

Player	Position	Played Minute	Technique	Tactic	Mentality	Physique	Total Score
Player 1	GK	90	3	3	3	3	3
Player 2	DF	90	2	3	2	2	2.25
Player 3	DF	90	2	3	3	3	2.75
Player 4	DF	73	3	3	3	2	2.75
Player 5	DF	90	2	3	2	2	2.25
Player 6	MF	90					None
Player 7	MF	90	2	2	2	2	2
Player 8	MF	90	3	3	3	3	3
Player 9	FW	90					None
Player 10	FW	90	2	3	3	3	2.75
Player 11	FW	45	2	3	2	2	2.25
Player 12		45	3	2	3	2	2.5
Player 13		17					None

4.1.4 Exempel på nätverksvisualisering av matchdeltagande

Figur 15 visar den nätverksgraf som representerar AIK:s deltagande i olika fotbollsmatcher, där varje blå nod är en specifik match där AIK spelat mot andra lag såsom Brommapojkarna, Malmö, Västerås och GAIS. De gröna noderna representerar deltagarna i varje match, vilket i detta fall är spelarna, men eftersom anonymitet upprätthålls visas endast unika identifierare (UUID) i stället för namn. Varje grön nod är sammankopplad med en blå nod genom en kant etiketterad "PARTICIPATED_IN", vilket indikerar spelarens deltagande i den specifika matchen. Denna visualisering gör det möjligt att se vilka spelare som deltog i vilka matcher och ger en klar översikt över lagets matchdeltagande under säsongen.

Genom att använda nätverksgrafen kan deltagarmönster analyseras effektivt, vilket möjliggör identifiering av vilka spelare som var mest aktiva samt undersökning av eventuella korrelationer mellan matchdeltagande och andra variabler såsom matchresultat eller spelarprestationer.




Figur 15: Nätverksgraf som visar AIK:s spelardeltagande i olika matcher

4.2 Verifiering och validering

För att säkerställa att applikationen uppfyller sina mål, genomfördes funktionstester. Resultaten från dessa tester presenteras nedan:

4.2.1 Funktionstest av datavisualisering

Syftet med funktionstestet av datavisualisering var att säkerställa att applikationen korrekt hanterar och visualiserar data från olika källor. Testprocessen inkluderade flera steg för att säkerställa att applikationen inte bara läste in olika dataformat korrekt utan också att den kunde visualisera dessa data enligt användarens specifikationer. Först genomfördes tester där CSV-filer från olika källor laddades upp för att utvärdera applikationens förmåga att tolka olika datastrukturer. Därefter ställdes specifika maxvärden in genom applikationens användargränssnitt för att testa dess flexibilitet i att justera visualiseringarna baserat på användardefinierade parametrar. Slutligen genererades diagram för att kontrollera att de korrekt återspeglade de inmatade datan och respekterade de inställda parametrarna. Diagrammen granskades också för att bekräfta att de automatiskt justerades för att säkerställa jämförbara resultat över olika datakällor.



Figur 16: Exempel på gränssnitt för att välja och visualisera spelardata från olika källor, med justerbara maxvärden och val av diagramtyp. Y-axeln visar procentuell betygsättning från olika datakällor.

4.2.2 Validering av användarvänlighet

Syftet med valideringen av användarvänligheten var att utvärdera användarvänlighet och effektivitet. Lagledaren från AIK:s ungdomsfotbollslag fick en demonstration av en första version av applikationen och fann den användarvänlig. Lagledaren märkte att man snabbt kunde ladda upp data, ställa in parametrar och generera diagram. Feedback indikerade att applikationen var enkel att använda och de grafiska representationerna av data var tydliga och hjälpsamma, men att man önskade kunna ställa in maxvärden för de olika parametrarna samt att få jämförelse av statistik över alla spelade matcher. Författarens tester av slutprodukten bekräftade dessa resultat och visade förbättrad navigering och funktionalitet.

4.2.3 Kontroll av Datainkonsistenser

Syftet med kontrollen av datainkonsistenser var att identifiera och förstå datainkonsistenser. Effektiviteten i att visualisera dessa inkonsistenser uppnåddes genom att presentera datan procentuellt i diagram, vilket gjorde det tydligt för användarna att jämföra och se skillnader mellan olika datakällor. Denna metod tillät en direkt visuell jämförelse av värden från olika matcher eller spelarstatistik, vilket belyste avvikelser och inkonsistenser på ett mycket klart och begripligt sätt. Användarna kunde enkelt upptäcka och förstå var och hur data skiljde sig åt, vilket var särskilt användbart för tränare och lagledare som behövde vidta åtgärder för att förbättra datakvaliteten.

Exempel på dessa visualiseringar och hur de framställde datainkonsistenser effektivt visas i figur 13 och 14 i avsnitten 4.1.1 och 4.1.2. Genom dessa verifierings- och valideringstester säkerställdes att

applikationen tekniskt och praktiskt uppfyllde sina mål att förbättra dataintegration och visualisering för tränare och ledare inom ungdomsfotboll.

4.3 Resultatet av dataanalysen

Denna del av rapporten presenterar resultaten från analyser av data insamlade från plattformarna SoccerLab, EyeBall och PlayMaker. För detaljerade resultat och visualiseringar, vänligen se bilagorna A, B och C.

4.3.1 Resultat av normalfördelning

Genom att använda histogram och QQ-plottningar undersöktes variablernas fördelningar bland samtliga plattformar för att bedöma deras normalitet.

4.3.1.1 SoccerLab

Vid analys av data från SoccerLab är det viktigt att notera att variablerna som Technique, Tactic, Mentality, Physique och Total score är av ordinal typ. Dessa variabler är inte kontinuerliga (så kallad intervalldata) utan kategoriska, vilket innebär att de representerar rangordnade kategorier snarare än exakta numeriska värden. Därför är dessa data inte lämpliga för parametriska metoder som kräver normalfördelade och kontinuerliga data.

Played Minute visar att majoriteten av spelarna har spelat hela matchen, vilket innebär att distributionen är kraftigt förskjuten mot 90 minuter och således inte är normalfördelad. När Technique analyseras, observerades att majoriteten av spelarna fick en poäng på 2, med en mindre grupp på 3 och ett fåtal på 1. Denna fördelning är inte normalfördelad eftersom den är koncentrerad vid specifika poängnivåer. Tactic uppvisade en liknande trend, där spelarna huvudsakligen fick poängnivåer på 2 och 3, vilket återigen visar en icke-normal fördelning.

Vid analys av Mentality, fanns en jämn fördelning mellan poängnivåerna 2 och 3, vilket också resulterar i en icke-normal fördelning. Physique visade en koncentration vid nivåerna 2 och 3, med få spelare på nivåerna 1 och 4, vilket indikerar en hög koncentration vid specifika poängnivåer. Total score för spelarna visade också en koncentration mellan nivåerna 2 och 3, vilket inte representerar en normalfördelad spridning.

Vid vidare analys med QQ-plottningar observerades att variabeln Technique var kraftigt grupperad vid specifika värden (2 och 3) med få avvikande värden, vilket bekräftar att variabeln inte är normalfördelad. Tactic visade tydliga kluster vid värdena 2 och 3, och liknande mönster observerades för Mentality och Physique, vilket indikerar att dessa variabler inte följer en normalfördelning.

4.3.1.2 EyeBall

På grund av det stora antalet variabler har endast de mest intressanta resultaten sammanfattats här. Histogrammet för rating visar en nära normal fördelning, vilket innebär att rating fördelar sig symmetriskt kring medelvärde och kan analyseras med parametriska metoder. Däremot visade histogrammen för antalet mål och assist starkt skevda fördelningar med många nollvärden, vilket indikerar att de flesta spelare gör få mål och assister. Liknande mönster observerades för frisparkar och inkast, vilket tyder på att dessa händelser är relativt sällsynta.

En analys av QQ-plottning för rating visar att fördelningen följer den röda linjen relativt väl, vilket bekräftar en nära normal fördelning. Fördelningarna av mål och assist visar dock klustrade punkter som avviker från den röda linjen, vilket bekräftar icke-normal fördelning. Frisparkar och inkast följer inte heller en normal fördelning enligt QQ-plottningen.

4.3.1.3 *PlayMaker*

Histogrammen för antalet aktioner per spel (Actions PG) och kedjor per spel (Chains PG) visar en nära normalfördelning, vilket indikerar att de flesta spelare utför en medelhög till hög mängd handlingar och kedjor per spel. Detta möjliggör användning av parametriska metoder i analysen.

I kontrast visade histogrammen för mål och assist per spel starkt skevda fördelningar med många nollvärden, vilket indikerar att de flesta spelare gör få mål och assister per match. Liknande mönster observerades för fouls och interceptioner per spel, vilket tyder på att dessa defensiva händelser är relativt sällsynta.

Analyser av QQ-plottningar visade att variabler som Actions PG och Possession Actions PG var närmast normalfördelade, vilket tyder på en jämn fördelning av dessa aktiviteter bland spelarna. Nyckelpassningar (Key Passes PG) och assist per skott (Shot Assists PG) var starkt förskjutna mot noll, vilket bekräftar att de flesta spelare gör få avgörande passningar och assist per match. Utmaningar (Challenges PG) och interceptioner per spel visade en betydande avvikelse från normalfördelningen, vilket indikerar att defensiva aktioner är relativt ovanliga. Playmaker Rank var relativt normalfördelad, vilket kan indikera en jämn spridning av playmaker-rollen bland spelarna.

4.3.2 Resultat av korrelationsmatris

Korrelationsmatriser genererades för att undersöka relationerna mellan variablerna med hjälp av Pearson-, Spearman- och Kendall-korrelationsmått. Pearsonkorrelationen användes för att analysera linjära relationer, medan Spearman och Kendall användes för att analysera monotona relationer och hantera eventuella outliers. Slutligen presenteras analyser där de summerade betygen kombineras med AIK:s kvalitativa mätningar för att undersöka interaktionerna mellan dessa variabler.

4.3.2.1 *SoccerLab*

Analysen av SoccerLab-data visade att det finns en tydlig positiv korrelation mellan Physique och Played Minute, vilket indikerar att spelare med bättre fysisk kondition tenderar att spela fler minuter. Mentality och Tactic visade också en stark koppling, vilket tyder på att spelare med bättre mentala egenskaper ofta har en god taktisk förmåga. Sambandet mellan Teknik och Taktik var något svagare, men det antyder ändå att teknisk skicklighet och taktisk medvetenhet ofta går hand i hand.

4.3.2.2 *EyeBall*

I EyeBall-data framkom det att det finns en stark positiv relation mellan Rating och Played Minute, vilket antyder att spelare som får längre speltid tenderar att få högre betyg. Goals Scored visade också en stark koppling till Rating, vilket tydligt indikerar att fler mål har en betydande inverkan på spelarens betyg. Sambandet mellan Shots och Goals Scored var också starkt, vilket bekräftar att fler skott ofta leder till fler mål. Freekicks och Played Minute visade en tydlig koppling, vilket antyder att spelare som spelar längre tid tenderar att få fler frisparkar.

4.3.2.3 *PlayMaker*

För PlayMaker-data visade Chains PG och Possession Actions PG en mycket stark positiv korrelation, vilket indikerar att fler kedjehandlingar är starkt kopplade till fler bollinnehavsaktiviteter. Interceptions PG visade också en stark koppling till Possession Actions PG, vilket tyder på att fler interceptioner ofta leder till fler bollinnehavsaktiviteter. Playmaker Rank visade en tydlig positiv relation med Played Minute, vilket indikerar att högre rankning ofta är förknippad med fler spelade minuter. Sambandet mellan Goals PG och Shots PG var mycket starkt, vilket bekräftar att fler skott nästan alltid leder till fler mål.

4.3.3 Resultat av regressionsplottningar

Nedan presenteras några av de mest intressanta resultaten från analysen av regressionsplottningar för SoccerLab, EyeBall och PlayMaker-plattformarna. Resterande regressionsplottningar för de summerade betygen samt AIK:s kvalitativa betyg finns att se i Bilaga E. Resultaten visade på både nära linjära och icke-linjära samband samt flera outliers, vilket har betydelse för valet av korrelationsmått.

4.3.3.1 *SoccerLab*


I de regressionsplottningar som presenteras i figur 17 för SoccerLab-plattformen illustreras olika dimensioner av spelarnas prestationer genom en analys av relationerna mellan speltid, fysiska egenskaper, taktiska och tekniska färdigheter, mental styrka och totalpoäng. Varje plottning bidrar med en visuell representation som underlättar förståelsen av hur dessa prestationsmått samspelar och påverkar varandra.

Den första plottningen, som jämför Played Minute med Physique, visar ett svagt linjärt samband. Detta antyder att längre speltid tenderar att korrelera med bättre fysisk kondition. Dock är detta samband inte starkt underbyggt, vilket framgår av spridningen och förekomsten av flera outliers. Detta indikerar att faktorer utöver speltid kan påverka spelarens fysiska kondition, eller att de mätmetoder som används för att bedöma fysik kanske inte konsekvent speglar spelarens faktiska fysiska förmåga.

Plottningen mellan Played Minute och Total Score visar en tendens där spelare med längre speltid också tenderar att uppnå högre totalpoäng. Liksom i den föregående plottningen finns dock brister i detta samband, där spridningen och outliers tyder på möjliga inkonsekvenser i hur totalpoängen sammanställs eller hur speltiden påverkar dessa poäng.

Analysen av relationen mellan Technique och Tactic avslöjar en svag linjär korrelation, vilket tyder på att tekniska färdigheter och taktiska kunskaper ofta utvecklas parallellt. Men även här är sambandet inte starkt, och spridningen av datapunkter samt förekomsten av outliers antyder att teknik och taktik inte alltid bedöms konsekvent. Detta kan reflektera variationer i hur dessa färdigheter värderas eller dokumenteras under olika spelsituationer.

Slutligen visar plottningen mellan Tactic och Mentality en korrelation där starkare taktiska färdigheter ofta åtföljs av högre mental styrka. Trots en tydlig linjär trend är datan spridd och det förekommer outliers, vilket signalerar att det finns variationer i hur dessa egenskaper samvarierar och bedöms, potentiellt påverkade av individuella skillnader i bedömning eller specifika kontexter under matcherna.



Figur 17: Resultat för några regressionsplottningar från SoccerLab

4.3.3.2 EyeBall


I de regressionsplottningar som presenteras i figur 18 för EyeBall-plattformen undersöks olika relationer mellan spelarnas speltid, betyg, antal mål, antal skott, fouls och gula kort, vilket ger en djupare förståelse för hur dessa variabler interagerar och påverkar varandra.

Den första plottningen mellan Played Minute och Rating indikerar ett svagt linjärt samband, där längre speltid möjligen kan associeras med något högre betyg för spelarna. Dock är detta samband relativt svagt, vilket återspeglas i den betydande spridningen av datapunkterna och förekomsten av flera outliers. Detta pekar på att faktorer utöver speltiden kan ha en inverkan på spelarens betyg, eller att betygssättningen inte konsekvent speglar speltiden.

Plottningen mellan Rating och Goals Scored uppvisar en positiv linjär trend, där spelare som gör fler mål tenderar att erhålla högre betyg. Trots denna tendens är tolkningen av sambandet begränsad på grund av närvaron av outliers, vilket antyder att sambandet mellan antalet gjorda mål och betyg inte är helt stabilt och kan påverkas av andra faktorer som inte direkt relaterar till målproduktionen.

Sambandet mellan Goals Scored och Shots, som illustreras i plottningen, tyder på att fler skott ofta leder till fler gjorda mål. Den linjära trenden är tydlig, men spridningen av datapunkterna och förekomsten av outliers indikerar att vissa spelare kan avvika från denna trend, vilket kan bero på faktorer som skotteffektivitet eller defensiva förhållanden under matcherna.

Slutligen framkommer i plottningen mellan Fouls och Yellow Cards en svag positiv linjär trend, vilket antyder att spelare som begår fler fouls också löper en högre risk att erhålla gula kort. Denna relation är emellertid inte stark, och antalet datapunkter är begränsat, vilket gör att sambandet framstår som osäkert och kan vara beroende av subjektiva faktorer såsom domarens bedömningar eller matchens intensitet.



Figur 18: Resultat för några regressionsplottningar från EyeBall


4.3.3.3 PlayMaker

För PlayMaker-plattformen undersöker regressionsplottningarna i figur 19 centrala samband mellan olika variabler som återspeglar spelarnas prestationer och deras bidrag till spelet. Plottningen mellan Chains PG och Possession Actions PG visar en stark positiv linjär trend, vilket indikerar att ett ökat antal bollinnehavssekvenser (Chains PG) ofta är associerat med fler handlingar med bollinnehav (Possession Actions PG). Denna relation framstår som relativt robust, med få outliers som stör tolkningen, vilket antyder att dessa två variabler är starkt sammanlänkade och kan fungera som betydelsefulla indikatorer på en spelares spelstil eller roll på planen.

I plottningen mellan Long Balls PG och Possession Actions PG observeras också en positiv linjär trend, vilket antyder att längre passningar tenderar att generera fler handlingar med boll. Dock förekommer en betydande spridning och flera outliers, vilket kan indikera att denna relation inte är lika stark eller att den är känslig för andra faktorer, såsom spelarens position eller lagets taktiska upplägg.

Sambandet mellan Shots och Goals PG, som framgår av plottningen, följer en förväntad positiv trend, där ett större antal skott ofta resulterar i fler mål. Trots detta påverkas relationens styrka av närvaron av outliers, vilket antyder att skottens effektivitet kan variera avsevärt och att andra faktorer kan ha en betydande inverkan.

Slutligen visar plottningen mellan Played Minute och Playmaker Rank en positiv linjär trend, vilket indikerar att spelare som spenderar mer tid på planen tenderar att ha en högre rankning. Trots den tydliga trenden bör analysen genomföras med noggrannhet på grund av de outliers som kan påverka resultatet, vilket antyder att speltid inte är den enda faktorn som påverkar en spelares playmaker-rankning.



Figur 19: Resultat för några regressionsplottningar från Playmaker

4.3.3.4 Summerade betyg och AIK:s kvalitativa betyg

För att ge en överblick över relationerna mellan variablerna Mentality, Technique, Tactic, Physique, Total score, Playmaker Rank och Rating har regressionsplottningar skapats. Dessa plottningar visar på komplexa och ofta icke-linjära samband, med närvaro av outliers som gör att sambanden bör tolkas med viss försiktighet. På grund av dessa utmaningar och de svaga relationerna mellan vissa variabler, är användningen av icke-parametriska metoder, såsom de som används i Bayesian network analysis, särskilt relevant. För en mer detaljerad visualisering av dessa regressionsplottningar, se bilaga E.

4.4 Resultat av bayesiansk nätverksanalys

4.4.1 Jämförelse mellan summerade betyg från plattformarna

I denna sektion undersöks relationerna mellan de summerade poängen från olika plattformar samt deras korrelation med AIK:s kvalitativa mätningar. Detta ger en insikt i hur olika plattformar bedömer spelare och hur dessa bedömningar förhåller sig till AIK:s egna mätningar.


4.4.1.1 Korrelationsanalys mellan summerade betyg

Korrelationsmatrisen visar relationerna mellan de summerade betygen från olika plattformar: Total score, rating och Playmaker Rank. Resultaten indikerar en måttlig positiv korrelation mellan rating och Playmaker Rank (0,37), vilket tyder på att spelare som får höga betyg i rating också tenderar att ha en hög Playmaker Rank. Detta samband är förväntat då båda dessa betyg utvärderar spelarens övergripande prestation, även om de fokuserar på olika aspekter.

Den Bayesianiska nätverksmodellen ger en djupare insikt i hur dessa summerade betyg påverkas av specifika variabler. Modellen visar att Total score främst påverkas av Played Minute (0,36), Technique (0,57) och Tactic (0,63), vilket indikerar att Total score prioriterar tekniska och taktiska färdigheter samt den tid spelaren spenderar på planen. Rating påverkas av Played Minute (0,37), Mentality (0,17) och Physique (0,27), vilket tyder på att rating betonar mentala och fysiska attribut utöver speltiden. Playmaker Rank påverkas mest av Played Minute (0,48), Physique (0,18) och Technique (0,13), vilket reflekterar en betoning på selfförståelse, teknisk skicklighet och fysisk kapacitet.

Dessa skillnader i vilka variabler som påverkar de olika summerade betygen förklarar varför rating och Playmaker Rank har en måttlig korrelation, medan korrelationen mellan Total score och de andra två variablerna är svagare, med ett värde på 0,19 för rating och 0,14 för Playmaker Rank. Total score fokuserar mer på tekniska och taktiska aspekter av prestation, vilket inte alltid är lika centralt i rating och Playmaker Rank.

Den Bayesianiska nätverksmodellen visar att de summerade betygen, även om de delvis överlappar, fångar olika aspekter av spelarnas prestationer. Detta belyser vikten av att inkludera alla tre betyg för en mer omfattande och nyanserad utvärdering av spelarna. Modellen visar också att olika variabler bidrar på olika sätt till de summerade betygen, vilket ytterligare förstärker behovet av att analysera dem med hjälp av icke-parametriska metoder som kan hantera komplexiteten i dessa beroenden.




Figur 20: Korrelationsmatris för de summerade betygen

4.4.1.2 Relationen mellan summerade betyg med AIK:s kvalitativa mätningar

För att förstå hur AIK:s kvalitativa mätningar (Mentality, Technique, Tactic, Physique) relaterar till de summerade betygen (Total score, rating, Playmaker Rank) genomfördes både en korrelationsanalys och en inferensanalys.

4.4.1.3 Korrelationsanalys mellan summerade betyg och AIK:s kvalitativa mätningar

Korrelationsmatrisen (se Figur 21) visar sambanden mellan AIK:s mätningar och de summerade betygen. Total score uppvisar en stark korrelation med både Mentality (0.71) och Tactic (0.63), medan sambandet med Technique och Physique är något svagare (0.58). När det gäller rating är sambanden med AIK:s mätningar generellt sett svaga, där den starkaste korrelationen är med Physique (0.28). Playmaker Rank har svaga korrelationer med samtliga AIK-mätningar, med den starkaste kopplingen till Physique (0.22) och Mentality (0.14).




Figur 21: Korrelationsmatris för summerade betyg och AIK:s kvalitativa mätningar

4.4.2 Bayesiansk nätverksmodell

För att bygga en tillförlitlig bayesian nätverksmodell analyserades först variablernas fördelningar och relationer. Histogram och QQ-plottningar användes för att bedöma normalfördelningen av variablerna, och korrelationsmatriser med Pearson, Spearman och Kendall korrelationsmått hjälpte till att identifiera de starkaste relationerna mellan variablerna. För att ytterligare motivera valet av korrelationsmått skapades regressionsplottningar för varje par av variabler. Dessa plottningar visade både linjära och icke-linjära relationer, samt identifierade outliers som kan påverka analysen.

Efter en noggrann förstudie och analys valdes Kendall som korrelationsmått för att bygga den bayesianska nätverksmodellen. Som tidigare nämnts i sektion 2.1.1 är Kendall en icke-parametrisk metod som är särskilt användbar när data inte är normalfördelad och när det finns ordinalskalade variabler. Dess robusthet mot outliers och dess förmåga att hantera associationer som inte är strikt monotona gör Kendall till ett lämpligt val för denna modell. Regressionsplottningarna visade att många av relationerna var icke-linjära och innehöll outliers, vilket ytterligare underströk behovet av ett robust korrelationsmått som Kendall.

Den slutliga modellen visade sig vara den mest robusta för att hantera den observerade datans egenskaper och komplexiteter. Genom att använda Kendall kunde modellen identifiera och representera både linjära och monotona relationer mellan variablerna, samtidigt som den hanterade outliers effektivt. Detta val kommer att motiveras och analyseras mer detaljerat i kapitlet Analys.



Figur 22: Resultat för bayesianska nätverksgrafen

Figur 22 visar de starkaste sambanden mellan variablerna i datasetet, där linjerna representerar direkta relationer identifierade i modellen. Modellen visade flera intressanta samband. Played Minute har en måttligt stark relation med rating (0,37), Physique (0,39) och Mentality (0,29), vilket indikerar att längre speltid ofta är förknippad med bättre fysisk och mental kondition samt högre betyg. En positiv koppling framträdde mellan rating och både Goals Scored (0,39) och assists (0,28), vilket bekräftar att spelare som gör fler mål och assist får högre betyg. Vidare visade sig rating ha en betydande relation med Playmaker Rank (0,42), vilket tyder på en viss överlappning i hur dessa variabler bedömer spelarens prestation.

Physique visade sig påverka rating (0,27) och Carries PG (0,29), vilket tyder på att bättre fysisk kondition inte bara bidrar till högre betyg, utan även till fler förflyttningar med bollen. Dessutom framkom en stark positiv korrelation mellan xG PG och Shots (0,70), vilket bekräftar att fler skott oftast leder till fler förväntade mål.

När det gäller sambandet mellan Chains PG och Actions PG (0,77), var detta särskilt starkt och indikerar att fler handlingar under spelet leder till fler bollinnehavssekvenser. Chains PG hade också en påtaglig relation med Carries PG (0,47), vilket antyder att fler kedjehandlingar ofta involverar fler förflyttningar med bollen.

4.4.3 Inferensanalys mellan summerade betyg och AIK:s kvalitativa mätningar

I denna sektion presenteras resultaten från inferensen med bayesianska nätverksmodellen där "Played Minute = 90" används som bevis. Genom att fokusera på spelare som har spelat hela matchen kan de variabler (Technique, Tactics, Mentality och Physique) som har störst påverkan på de summe-

rade betygen (Total score, rating och Playmaker Rank) identifieras och analyseras. För att tolka variablernas betydelse (viktighet, en: importance) har en metodik använts som beskrivs i kapitel 3.3.5. Viktigheten (värdet inom parentes) kvantifieras genom att mäta skillnaden i sannolikhet för den undersökta variabeln, både med och utan den extra evidensvariabeln. Om sannolikheten förändras avsevärt när en ny variabel introduceras som bevis, indikerar detta att variabeln har ett starkt inflytande på resultatet.

För att ytterligare undersöka sambanden mellan AIK:s mätningar och de summerade betygen, genomfördes en inferensanalys där varje summerat betyg undersöktes i relation till AIK:s egna mätningar.

Total score:

- Tactic (0,142) visade sig ha störst påverkan på Total score, följt av Mentality (0,071), Technique (0,069), och Physique (0,066). Detta indikerar att taktiska färdigheter och mental styrka är de viktigaste faktorerna som bidrar till en hög Total score.

rating:

- Mentality (0,032) och Physique (0,03) är de mest betydelsefulla faktorerna som påverkar rating, medan Technique (0,009) och Tactic (0,001) har en betydligt mindre påverkan. Denna analys visar att mental och fysisk kondition har en större inverkan på spelarbetyget jämfört med tekniska och taktiska färdigheter.

Playmaker Rank:

- För Playmaker Rank är Technique (0,093) den mest inflytelserika faktorn, följt av Physique (0,08) och Mentality (0,068). Tactic (0,057) spelar en mindre roll jämfört med de andra faktorerna.

4.4.4 Resultat av inferens från bayesiansk nätverksmodell

I detta delkapitel presenteras resultaten från inferensen med bayesianska nätverksmodellen för att fastställa vilka variabler som har störst påverkan på de summerade betygen.

4.4.4.1 Signifikanta samband med rating

De fem viktigaste variablerna för rating är Chains PG, goalsScored, Goals PG, Tackles PG och Efficiency. Tabell 2 visar att Chains PG, som representerar antalet bollinnehavsekvenser per spelad match, har den största påverkan på rating. Detta indikerar att en spelares förmåga att kontinuerligt bidra till anfallsspel genom att delta i bollinnehav är avgörande för deras totala rating. Även goalsScored och Goals PG är centrala faktorer, vilket understryker vikten av att göra mål för att höja en spelares rating. Vidare visar Tackles PG och Efficiency att defensivt arbete och spelarsäkerhet också spelar en betydande roll i att bestämma en spelares prestation. Tillsammans framhäver dessa variabler hur både offensiva och defensiva aspekter av spelet påverkar en spelares rating.

Tabell 2: Tabell för de mest signifikanta variablerna för rating

	Variabel	Viktighet
0	Chains PG	0.971427
1	goalsScored	0.165501
2	Goals PG	0.135804
3	Tackles PG	0.105944
4	Efficiency	0.096688
5	Challenges PG	0.0890019
6	shots	0.0708759
7	Fouls	0.062851
8	Actions PG	0.0625942
9	Carries PG	0.0585412

4.4.4.2 Signifikanta samband med Total score

För Total score är de fem viktigaste variablerna Chains PG, rating, Tactic, Passes PG och Key Passes PG. Tabell 3 visar att Chains PG har den största påverkan på Total score, detta indikerar att en spelares deltagande i sammanhängande spel är avgörande för att uppnå ett högt värde för AIK:s summerade betyg. Rating och Tactic är också viktiga, vilket tyder på att både spelarens generella prestationsbedömning och deras taktiska förmåga är betydande faktorer. Passes PG och Key Passes PG belyser vikten av passningsspelet och nyckelpassningar för att påverka den totala poängen. Tillsammans understryker dessa variabler hur samspel, taktisk förståelse och precision i passningsspelet bidrar till en högre Total score.

Tabell 3: Tabell för de mest signifikanta variablerna för Total score

	Variabel	Viktighet
0	Chains PG	0.785215
1	rating	0.151778
2	Tactic	0.142391
3	Passes PG	0.134648
4	Key Passes PG	0.114907
5	Actions PG	0.106035
6	Aerials PG	0.0736306
7	Shot Assists PG	0.0729091
8	Points PG	0.0727821
9	Mentality	0.0716988

4.4.4.3 Signifikanta samband med Playmaker Rank

De fem viktigaste variablerna för Playmaker Rank är Chains PG, Technique, Aerials PG, rating och Possession Actions PG. Tabell 4 visar att Chains PG har den största påverkan på Playmaker Rank, vilket indikerar att förmågan att skapa och delta i passningskedjor är kritisk för en spelare som rankas

högt av plattformen Playmaker. Technique och Aerials PG visar att teknisk skicklighet och förmågan att vinna luftdueller också är viktiga för ens Playmaker betyg. Rating och Possession Actions PG förstärker vikten av spelarens generella prestation och deras förmåga att behålla bollen i laget.

Tabell 4: Tabell för de mest signifikanta variablerna för Playmaker Rank

	Variabel	Viktighet
0	Chains PG	0.842551
1	Technique	0.0925223
2	Aerials PG	0.087733
3	rating	0.08332
4	Possession Actions PG	0.0809714
5	Physique	0.079845
6	Actions PG	0.0765698
7	Carries PG	0.0739291
8	Receptions PG	0.0694572
9	Challenges PG	0.0685958

5 Analys och diskussion

I detta kapitel genomförs en djupgående analys och diskussion av resultaten som presenterats i kapitel 4, resultat för typiska diagram och nätverksgrafer. Analysen knyter an till de mål som fastställdes i avsnitt 1.2 samt de metoder som beskrivs i kapitel 3. Delkapitel 5.1 till 5.4 tar upp i respektive sektion en detaljerad granskning av de fyra målen som sattes upp. Diskussion i förhållande till tidigare forskning belyses i 5.5, mål och förväntningar nämns i 5.6 och verifiering och framtida arbeten diskuteras i 5.7.

Detta examensarbete bidrar samhällsmässigt genom att integrera ett bredare systemperspektiv i analysen av sportdata, vilket vanligtvis behandlar spelare som enkla agenter begränsade till fysiska aktioner som att sparka och passa en boll samt att göra mål. Genom att inkludera kvalitativa bedömningar av spelarnas mentala, fysiska, taktiska och tekniska färdigheter, ger arbetet en mer omfattande bild av spelarnas prestationer och välbefinnande. Dessa aspekter är avgörande för att förstå hur olika dimensioner av en spelares tillstånd påverkar deras kvantitativa prestanda på planen.

Etiskt sett kan detta arbetes tillvägagångssätt ses som ett steg mot en mer holistisk syn på spelaranalys inom ungdomsfotboll. Det belyser vikten av att balansera den kvantitativa datadrivna analysen med kvalitativa insikter, vilket kan bidra till en mer rättvis och informerad bedömning av spelarnas färdigheter och kapacitet. Genom att uppmärksamma de mentala och fysiska aspekterna av spelarnas prestationer, erkänns spelarnas individuella behov och välbefinnande, vilket är kritiskt inte bara för deras utveckling som atleter utan också för deras allmänna hälsa.

Ekonomiskt och miljömässigt bidrar projektet till minskade kostnader och ekologiskt fotavtryck. Digitaliseringen reducerar behovet av fysisk lagring och pappersanvändning, vilket gynnar miljön genom minskad resursförbrukning och avfall. Ekonomiskt effektiviserar det även tränarnas och ledarnas arbete genom att minska den tid de lägger på datahantering, vilket frigör tid för spelarutveckling och strategisk planering. Dessa aspekter visar på projektets potential att bidra positivt till både fotbollsklubbarnas resurshantering och miljön.

5.1 Analys över dynamisk datahantering

Att uppnå dynamisk datahantering presenterade betydande utmaningar, särskilt givet den metod som valdes att implementera. För att hantera datan dynamiskt, beslutades att lagra all information i JSON-format i en MySQL-databas. Detta tillvägagångssätt gjorde det möjligt att kontinuerligt tillföra nya datafiler. Denna flexibilitet kom dock med en kostnad: det begränsade min förmåga att fullt ut utnyttja de funktioner som en relationsdatabas erbjuder, framför allt förmågan att ställa komplexa frågor direkt mot datan.

För att delvis kompensera för denna begränsning, lagrades matchernas namn i en separat kolumn. Detta gjorde det möjligt att utföra vissa specifika databasfrågor. Dock är frågeställningar som riktas mot hela JSON-strukturen inte hållbara på lång sikt, givet dess omfång och komplexitet. Detta pekar på att en dokumentbaserad databas som MongoDB skulle ha varit ett mer effektivt val för detta projekt. En djupare diskussion om detta kommer att presenteras i kapitel 5.3.

5.1.1 Förbättringspotential

Som nämnt tidigare lyckades implementationen av en lösning som dynamiskt kan hantera all nuvarande och framtida data, men detta på bekostnad av systemets prestanda. En potentiell alternativ lösning för att fortsätta arbetet inom ramen för MySQL skulle kunna innebära skapandet av dynamiska kolumner, baserade på de rubriker som finns i CSV-filerna. Detta skulle möjliggöra en mer flexibel och effektiv datahantering och samtidigt upprätthålla förmågan att ställa databasfrågor på ett mer traditionellt sätt.

5.2 Analys över filformat

Hantering av olika typer av avgränsare i CSV-filer krävde en fördjupad förståelse för CSV-formatet och dess variationer. Ursprungligen antogs att kommatecken (",") var den enda giltiga avgränsaren, men det blev snart uppenbart att även semikolon (";") och andra tecken används brett som avgränsare. Denna insikt komplicerade uppgiften, eftersom det nu krävdes att en metod utvecklades för att automatiskt detektera och standardisera vilken avgränsare som användes i inkommande filer.

Ytterligare en utmaning var att avgöra om avgränsaren var en del av datainnehållet eller faktiskt användes som en avgränsare. Detta ledde till utvecklingen av en logik som inte bara identifierade avgränsaren utan också korrekt tolkade innehållet mellan dem, vilket är kritiskt för att bibehålla dataintegriteten. Denna process och dess tekniska genomförande beskrivs i detalj i kapitlet 3.2.1.

5.2.1 Förbättringspotential

En möjlig förbättring av detta system skulle vara att utveckla en mer avancerad detekteringslogik som kan identifiera och hantera ett bredare spektrum av okonventionella avgränsare. Genom att implementera en flexibel tolkningsstrategi som kan anpassa sig till olika dataformat utan att kräva manuell intervention, kan systemet bli mer robust och användarvänligt.

5.3 Analys om persistent lagring

Som diskuterats i kapitel 2.3, presenteras både för- och nackdelar med användningen av en relationsdatabas som MySQL. En betydande begränsning med MySQL är dess hantering av JSON-data, där dokumentbaserade databaser som MongoDB erbjuder mer effektiva lösningar. Trots detta valdes MySQL primärt på grund av min tidigare erfarenhet och komfort med tekniken, samt dess förmåga att smidigt hantera strukturerad datahantering.

I detta examensarbete, där datan huvudsakligen består av information kopplad till ungdomslaget i AIK, är datamängden hanterbar inom MySQL:s kapacitet utan att prestanda blir ett problem. Denna databas erbjuder robusta verktyg för att upprätthålla relationell integritet och utföra komplexa SQL-frågor, vilket är fördelaktigt för de krav som mitt projekt ställer.

5.3.1 Förbättringspotential

Även om MySQL är tillräckligt för nuvarande databehov, bör man överväga att övergå till en dokumentbaserad databas som MongoDB vid en eventuell utbyggnad av applikationen. En sådan övergång skulle kunna hantera större och mer komplexa datamängder mer effektivt. MongoDB's förmåga att snabbt processa och indexera JSON-format kan erbjuda snabbare åtkomst och flexibilitet, vilket är avgörande när applikationen skalar upp och kräver mer dynamisk datahantering.

5.4 Analys om integreringen av neo4j grafdatabas

Integrationen av grafdatabasen Neo4j i mitt projekt var framgångsrik, men den mötte också flera utmaningar som påverkade implementeringen och funktionaliteten. En av de primära svårigheterna var att korrekt identifiera och matcha individer som hade sina namn stavade på olika sätt i olika datakällor. Denna inkonsekvens i namnhanteringen ledde till svårigheter att konsistent koppla rätt spelare med rätt prestationer och matcher.

Ursprungligen var avsikten att skapa flera relationer mellan samma noder (spelare och matcher) för att indikera att attributen för varje relation kom från unika CSV-filer. Tyvärr visade sig denna strategi vara otillräcklig på grund av tekniska begränsningar och komplexiteten i att hantera multipla relationer med unika attribut. Resultatet blev att begränsningen till endast en relation med samlade data från alla relevanta källor mellan en spelare och matchen var nödvändig.

På grund av tidsbegränsningar valdes det att endast fokusera på skapandet av grundläggande noder för spelare och matcher samt deras grundläggande relationer. Denna avgränsning var nödvändig för att säkerställa att projektet kunde genomföras inom den tillgängliga tiden, men det begränsade möjligheten att fullt ut exploatera grafdatabasens kapacitet för att hantera mer detaljerade och komplexa datarelationer.

5.4.1 Förbättringspotential

En potentiell lösning för att hantera namnvariationer skulle vara att utveckla en mer avancerad logik för namnhantering. Denna skulle kunna innefatta algoritmer för fuzzy matching som kan identifiera och sammanföra varianter av samma namn, även när de skrivs olika eller inkluderar ytterligare mellannamn. Genom att använda tekniker som naturlig språkbehandling (NLP) eller maskininlärning kan systemet lära sig att känna igen och koppla samman namn baserat på sannolikhet och likhetsberäkningar, vilket skulle förbättra dataintegriteten och tillförlitligheten i spelarstatistik.

5.5 Analys av dataanalysen

5.5.1 Analys av normalfördelning

Analysen av variablernas normalfördelning med hjälp av histogram och QQ-plottningar visade att de flesta variabler, såsom Technique, Tactic, Mentality och Physique, inte är normalfördelade. En möjlig anledning till detta är att värdena är satta av spelarnas coacher, som använder en matris för att specificera vad spelarna behöver uppfylla för att uppnå vissa poängnivåer. I praktiken innebär detta att bedömningarna kan vara subjektiva och påverkas av mänskliga faktorer som coachens känslor, erfarenhet, eller förväntningar på spelaren. Dessa faktorer kan leda till missbedömningar eller felaktiga värderingar, vilket kan förklara varför poängfördelningarna är förskjutna eller klustrade snarare än jämnt fördelade.

Det är också möjligt att coacherna tenderar att ge mer mellannivåbetyg snarare än extremvärden, vilket skulle resultera i en klustring av poäng runt vissa specifika nivåer, snarare än en spridning som skulle reflektera en normalfördelning. Detta skulle kunna vara ett resultat av en önskan att undvika att vara alltför kritisk eller alltför generös i sina bedömningar, eller en ovilja att ge ut värderingar som kan verka extremt avvikande.

Denna subjektivitet i bedömningen kan påverka tillförlitligheten av den insamlade datan och i sin tur påverka resultaten av statistiska analyser. Det understryker också vikten av att använda icke-parametriska metoder, såsom Kendall-korrelationen, som är mer robusta mot sådana avvikelser i data. Att förstå och erkänna dessa begränsningar i datainsamlingen är avgörande för att korrekt tolka resultaten och för att identifiera områden där ytterligare förbättringar eller standardiseringar kan behövas i framtida dataanalys och bedömningsprocesser.

5.5.2 Analys av korrelationsmatriser

Korrelationsmatriserna, baserade på Pearson-, Spearman- och Kendall-korrelationer, visar att det finns starka relationer mellan vissa variabler, medan andra är svagt eller inte alls korrelerade. Exempelvis visade Technique och Tactic samt Mentality och Physique starka positiva korrelationer, vilket indikerar att dessa egenskaper ofta utvecklas och kan vara svåra att skilja åt i bedömningen. Detta är avgörande för att förstå vilka variabler som tenderar att samvariera och hur dessa samvariationer kan påverka spelarens totala prestation.

En möjlig förklaring till dessa starka korrelationer kan vara att poängsättningen för dessa variabler är subjektiv och baseras på coachernas bedömningar. Eftersom coacherna använder en specifik matris för att sätta poäng, och dessa bedömningar kan vara påverkade av deras personliga uppfattningar och känslor, är det möjligt att vissa variabler tenderar att samvariera eftersom coacherna bedömer dem tillsammans eller i liknande kontexter. Till exempel kan en coach som ser en spelare som taktiskt stark också vara benägen att ge höga poäng på teknik, även om dessa egenskaper inte nödvändigtvis är kopplade i verkligheten. Detta kan leda till att korrelationerna mellan dessa variabler verkar starkare än de skulle vara i en mer objektiv bedömning.

Denna insikt understryker vikten av att inte enbart förlita sig på statistiska korrelationer, utan också att noggrant överväga den kontext inom vilken data har samlats in. Det är också en påminnelse om att korrelation inte nödvändigtvis innebär kausalitet, särskilt när data kan vara påverkade av subjektiva bedömningar. För framtida studier skulle det vara värdefullt att utforska metoder för att minska subjektiviteten i bedömningarna, till exempel genom mer standardiserade och objektiva mätverktyg. Det kan också övervägas om dessa starkt korrelerade variabler kan slås samman eller om ytterligare riktlinjer behövs för att tydligare definiera och särskilja dem i bedömningsprocessen.

5.5.3 Analys av regressionsplottningar

De regressionsplottningar som presenteras visar en blandning av linjära, monotona, och icke-linjära samband, men en gemensam nämnare för de flesta plottningarna är närvaron av många outliers. Undantaget är relationen mellan Chains PG och Possession Actions PG, som visar en stark linjär trend med få outliers. Förutom denna linjära relation observeras flera monotona samband i de andra plottningarna, där variabler tenderar att röra sig i samma riktning utan att följa en strikt linjär kurva.

5.5.3.1 SoccerLab

För SoccerLab-plattformen visade regressionen mellan Physique och Played Minute en svag linjär trend, men med många outliers. Detta indikerar att även om det finns en viss koppling mellan fysisk styrka och speltid, påverkas denna relation starkt av spelare som avviker från normen. Trots den linjära trenden är sambandet svagt och påverkas av dessa avvikelser. Tactic och Mentality visade en positiv monoton relation med stor spridning och många outliers, vilket antyder att dessa två egenskaper ofta utvecklas tillsammans, men att deras samvariation inte alltid följer en linjär kurva.

Technic och Tactic visade också en positiv monoton relation med betydande spridning och många outliers. Även om tekniska och taktiska färdigheter ofta går hand i hand, är sambandet inte starkt och påverkas av variationer bland spelarna. Relationerna mellan Played Minute och Total Score visade en svag linjär trend, men även här finns flera outliers som påverkar tolkningen av sambandet mellan speltid och total poäng.

5.5.3.2 *EyeBall*

För EyeBall-plattformen visade regressionen mellan Played Minute och Rating en svag linjär trend med många outliers. Detta antyder att längre speltid kan korrelera med en högre rating, men att detta inte är ett konsekvent mönster för alla spelare, vilket gör att sambandet mer liknar en svag monoton relation än en strikt linjär. Rating och Goals Scored visade en positiv monoton relation, men med många outliers, vilket indikerar att fler gjorda mål generellt leder till en högre rating, men att detta samband varierar beroende på kontext.

Regressionen mellan Goals Scored och Shots visade en tydlig positiv monoton relation, vilket är logiskt då fler skott på mål oftast resulterar i fler mål. Trots många outliers bevaras det monotona sambandet, vilket betyder att när en variabel ökar tenderar den andra också att öka. Däremot visade regressionen mellan Fouls och Yellow Cards en svag monoton relation med flera outliers, vilket tyder på att fler fouls ofta leder till fler gula kort, men att detta samband inte alltid är starkt på grund av de avvikelser som observerats.

5.5.3.3 *PlayMaker*

För PlayMaker-plattformen visade regressionen mellan Chains PG och Possession Actions PG en stark linjär trend med få outliers, vilket indikerar en konsekvent och pålitlig relation mellan dessa variabler. Detta är det enda exemplet där en linjär relation observerades utan betydande avvikelser, vilket gör det till en särskilt viktig insikt.

Däremot visade relationen mellan Long Balls PG och Possession Actions PG, samt mellan Shots och Goals PG, tydliga positiva monotona trender men med många outliers. Detta antyder att även om dessa variabler är starkt korrelerade och tenderar att röra sig i samma riktning, är sambanden inte strikt linjära och påverkas av avvikande datapunkter. Relationerna mellan Played Minute och Playmaker Rank visade också en positiv monoton relation med många outliers, vilket indikerar att speltid påverkar en spelares betyg för Playmaker Rank, men denna påverkan är inte universell eller linjär.

5.5.3.4 *Summerade betyg och AIK:s kvalitativa betyg*

De regressionsplottningar som analyserar relationerna mellan AIK:s kvalitativa mätningar (Mentality, Technique, Tactic, Physique) och summerade betyg som Total score, Playmaker Rank, och Rating visade både linjära och monotona samband, med en tydlig närvaro av många outliers. Exempelvis visade relationen mellan Technique och Tactic en positiv monoton relation, där högre tekniska färdigheter ofta sammanfaller med högre taktiska bedömningar, trots spridning och outliers.

Relationerna mellan Physique och Total score samt mellan Played Minute och Total score visade också positiva monotona trender med många outliers. Detta tyder på att även om dessa variabler tenderar att röra sig i samma riktning, är relationerna inte starka och påverkas av flera avvikande datapunkter.

5.5.4 Motivering till valet av Kendall för nätverksmodellen

Valet av Kendall-korrelationen för den bayesianska nätverksmodellen är motiverat av flera faktorer relaterade till datans typ, fördelning och naturen av relationerna mellan variablerna. Enligt Field är valet av korrelationsmått avgörande och bör baseras på datafördelningen och typen av relationer som ska undersökas. Pearson-korrelationen är optimalt för att mäta graden av linjärt samband mellan två variabler när datan är normalfördelad. Eftersom många variabler i vår dataset inte visade en normalfördelad fördelning, vilket framkom i tidigare analyser, skulle användningen av Pearson-korrelationen ha varit olämplig.

För att hantera icke-normalfördelade data och för att mäta monotona relationer, är Spearman rank-korrelation ett robust alternativ som också är tåligt mot outliers och lämpar sig för ordinala data. Dock, med tanke på datans komplexitet och närvaron av många lika värden samt potentiellt små datamängder för vissa variabler, blev Kendall tau det mest lämpliga valet. Kendall tau är särskilt användbart när det finns många lika värden eller när datasetet är litet, och det ger en mer stabil uppskattning av monotona relationer jämfört med Spearman-korrelationen.

Genom att välja Kendall-korrelationen säkerställdes att modellen kunde hantera datans specifika egenskaper och att de viktigaste relationerna mellan variablerna kunde identifieras och tolkas korrekt, trots de utmaningar som datan presenterade. Detta val visade sig vara avgörande för att bygga en robust och pålitlig bayesiansk nätverksmodell, som kunde hantera både linjära och icke-linjära relationer samt outliers effektivt.

Denna motivering understryker vikten av att anpassa analysmetoderna till datans unika egenskaper och att noggrant överväga vilka korrelationsmått som är bäst lämpade för att dra tillförlitliga slutsatser i en given kontext.

5.5.5 Huvudsakliga fynd och begränsningar

Under arbetet med att analysera data från AIK:s ungdomslag framkom flera viktiga insikter. För det första upptäcktes tydliga positiva korrelationer mellan vissa variabler, särskilt mellan Technique och Tactic samt Mentality och Physique. Dessa korrelationer tyder på att dessa egenskaper ofta utvecklas tillsammans, vilket är avgörande för att förstå spelarnas totala prestationer. En annan viktig observation är att analysen med den bayesianska nätverksmodellen visade att Chains PG är en av de mest inflytelserika variablerna för både Rating, Total score och Playmaker Rank. Detta antyder att en spelares förmåga att delta i kontinuerliga spelsekvenser är avgörande för att höja deras betyg. Det framkom även att bedömningarna som coacherna gör är subjektiva, vilket har resulterat i att flera variabler inte är normalfördelade. Denna subjektivitet blir särskilt tydlig i de starka klustringarna av poäng kring vissa specifika nivåer, vilket kan påverka resultatens tillförlitlighet.

Trots dessa insikter finns det flera begränsningar som måste beaktas. En betydande begränsning är den subjektiva naturen av de poäng som coacherna sätter. Eftersom dessa poäng baseras på coachernas personliga bedömningar och kan påverkas av faktorer som känslor och förväntningar, är det svårt att säkerställa en konsekvent och objektiv bedömning över hela datasetet. Detta gör det också utmanande att tydligt separera effekterna mellan de olika dimensionerna, såsom physique, mentality, technique och tactic. Dessutom begränsas generaliserbarheten av resultaten på grund av den specifika kontexten och den relativt lilla storleken på datasetet.

Eftersom analysen baseras på data från en säsong med 26 matcher, kan det vara otillräckligt för att dra breda slutsatser om fotbollsspelare generellt. Vidare visade de flesta regressionsplottningarna på betydande närvaro av outliers, vilket indikerar att de linjära eller monotona relationerna mellan variablerna inte är helt stabila. Detta begränsar användbarheten av vissa statistiska metoder och försvårar tolkningen av relationerna mellan variablerna. Slutligen innebär valet av Kendall-korrelationen, trots att det är ett robust alternativ för icke-normalfördelade data, att vissa linjära relationer kanske inte fångades lika väl som de kunde ha gjort med andra metoder, vilket är en begränsning i analysen.

5.6 Diskussion i förhållande till tidigare forskning - applikationen

För att sätta detta arbete i ett bredare forskningssammanhang, jämförs här resultaten med tidigare studier inom området sportanalytik och dataintegration.

5.6.1 Dataintegration i sportanalytik

Bai *et al.* (2) diskuterar tekniska utmaningar och möjligheter i att samla in, säkra och behandla stora datamängder inom sportanalytik. Denna studie betonar behovet av att integrera data från olika källor för att få en omfattande bild av spelarprestationer. Arbetet med att utveckla en applikation som centraliserar och hanterar data från olika plattformar (Soccerlab, Eyeball och Playmaker) återspeglar dessa utmaningar och möjligheter. Genom att använda JSON-format i en MySQL-databas och dynamiskt kunna hantera inkommande datafiler, hanteras integreringsaspekten som Bai *et al.* diskuterar.

5.6.2 Visualisering av sportdata

Wexler *et al.* (4) betonar vikten av att välja rätt teknik för dataframställning för att säkerställa att visualiseringen är informativ och användbar. Enligt deras studie är stapeldiagram effektiva för att göra enkla jämförelser mellan olika mätvärden. Genom att använda Chart.js för att skapa stapeldiagram över spelarprestationer, följer arbetet rekommendationerna från Wexler *et al.*. Användartester visade att tränare och lagledare kunde använda dessa visualiseringar för att snabbt identifiera och förstå datainkonsistenser, vilket stämmer överens med Wexler *et al.* betoning på användbar visualiseringsteknik.

5.6.3 Datakvalitet och konsistens

Vicknair *et al.* (7) undersöker användningen av grafdatabaser (Neo4j) och relationsdatabaser (MySQL) för att hantera data med komplexa relationer. De fann att Neo4j presterar bättre för frågor som involverar komplexa grafraverseringar. Genom att använda Neo4j för att hantera relationer mellan spelare och matcher, utnyttjas dess styrkor i att hantera komplexa relationer, vilket Vicknair *et al.* framhåller. Denna integrering gör det möjligt att visualisera nätverk av spelardeltagande och prestationer på ett sätt som är svårare att uppnå med enbart en relationsdatabas.

5.6.4 Diskussion

Resultaten från detta arbete stämmer överens med tidigare forskning som understryker vikten av dataintegration och effektiv visualisering i sportanalytik. Bai *et al.* lyfter fram behovet av att centralisera och säkra data, vilket har återspeglats i utvecklingen av applikationen som hanterar data från flera källor. Wexler *et al.* betonar vikten av användarvänliga visualiseringar, vilket bekräftas av användar-

tester som visade att tränare kunde använda stapeldiagram för att identifiera och förstå datainkonsistenser. Vicknair *et al.* fann att grafdatabaser som Neo4j är effektiva för att hantera komplexa relationer, en insikt som tillämpats för att visualisera relationer mellan spelare och matcher.

5.7 Diskussion i förhållande till tidigare forskning – dataanalys

5.7.1 Bayesianiska nätverksmodellers användbarhet

Enligt Korb *et al.* (17) är bayesianska nätverksmodeller särskilt effektiva för att hantera osäkerheter och komplexa beroenden mellan variabler. Våra resultat stödjer denna synpunkt genom att visa hur modellen framgångsrikt kunde identifiera viktiga variabler och deras relationer, trots datans komplexitet och de varierande fördelningarna. Denna flexibilitet och anpassningsbarhet, som Korb *et al.* beskriver, visade sig vara avgörande för att dra tillförlitliga inferenser från datan.

Nielsen *et al.* (18) har betonat modellernas användbarhet inom medicinsk diagnostik och beslutsstödssystem, vilket parallellt kan överföras till sportanalys. Vår studie visar att bayesianska nätverksmodeller kan förbättra beslutsfattandet inom sportanalys genom att tillhandahålla en probabilistisk representation av osäkerhet och relationer mellan variabler, vilket är i linje med deras forskning.

5.7.2 Vikten av föranalys

Field (13) betonar vikten av en noggrann föranalys av data för att säkerställa att den valda modellen passar data väl och ger tillförlitliga resultat. Våra resultat visar att flera variabler inte var normalfördelade, vilket innebar att parametriska metoder kunde vara olämpliga. Denna insikt ledde till valet av Kendall-korrelationen för bayesianska nätverksmodellen, eftersom den är robust mot outliers och kan hantera ordnade data. Detta stödjer Fields argument om att förstå datafördelningen är kritiskt för att välja rätt analysmetoder.

5.7.3 Val av korrelationsmått

Valet av Kendall-korrelationen motiverades av dess robusthet mot outliers och förmåga att identifiera monotona, icke-linjära relationer, vilket bekräftas av Fields forskning (13). Kendall-korrelationen visade sig vara mest lämplig för att bygga vår bayesianska nätverksmodell eftersom många variabler i vårt dataset inte var normalfördelade och visade monotona relationer. Detta val visade sig vara effektivt för att hantera komplexiteten i data och säkerställa att de viktigaste relationerna fångades korrekt.

5.8 Mål och förväntningar

Mina mål för detta projekt har framgångsrikt uppnåtts, och de initiala förväntningarna har inte bara mötts utan i vissa avseenden överträffats. En av de mest givande aspekterna av projektet var integrationen av en grafdatabas, vilket möjliggjorde skapandet och visualiseringen av nätverksgrafer. Denna funktionalitet bidrog betydligt till att fördjupa förståelsen för spelardeltagande i olika matcher, vilket var både intressant och informativt. Dessa visualiseringar har inte bara förbättrat min egna förståelse utan har också potential att erbjuda tränare och andra intressenter en djupare inblick i spelarnas prestationer och engagemang. Detta kan i sin tur leda till mer informerade beslut när det gäller laguppställningar och träningsscheman.

Utöver detta, genomfördes en omfattande dataanalys med hjälp av bayesianska nätverksmodeller för att identifiera de mest inflytelserika variablerna som påverkar spelarens betyg och prestationer. Denna kombinerade metod, med både applikationsutveckling och avancerad dataanalys, har gett en bred och djup förståelse för spelarprestationer. Grafdatabasen och visualiseringen av nätverksgrafer

hjälpte till att kartlägga och förstå spelarnas deltagande och interaktioner på planen. Samtidigt möjliggjorde bayesianska nätverksmodellen en detaljerad analys av hur olika faktorer påverkar spelarprestationerna, vilket ger värdefulla insikter för att optimera lagets prestationer.

5.9 Verifiering och framtida arbete

Verifiering av applikationens funktionalitet genomfördes genom både användartester och interna tester för att säkerställa att applikationen uppfyller sina mål. Användartester genomfördes för att identifiera datainkonsistenser. Under ett tidigare stadium av applikationsutvecklingen demonstrerades dess funktionaliteter för lagledaren från AIK:s ungdomsfotbollslag. Lagledaren fick se hur man laddade upp data sparad lokalt på datorn till applikationen. Trots att applikationen inte var helt färdig vid detta tillfälle, kunde användaren snabbt identifiera inkonsekvenserna i datan, vilket tidigare krävde manuella och tidskrävande jämförelser. Vid denna demonstration gavs feedback på att lägga till ytterligare funktionaliteter, såsom jämförelse av statistik över alla spelade matcher.

Efter att applikationen färdigställdes genomfördes ytterligare interna tester av författaren själv för att säkerställa att alla funktionaliteter fungerade som avsett. Dessa tester inkluderade följande:

- Översikt av spelarprestationer: Applikationen testades för att verifiera att den gav en tydlig och sammanhängande översikt av spelarnas prestationer. Den visualiserade datan på ett användarvänligt sätt som underlättade förståelsen av varje spelares utveckling och prestationer över tid.
- Jämförelse av data över matcher: En ny funktionalitet implementerades för att jämföra data över alla spelade matcher. Denna funktionalitet testades och bekräftades fungera bra, vilket ger användarna en mer omfattande bild av spelarprestationer över säsongen.

Tekniska utmaningar inkluderade implementering av logik för att identifiera när dataposter avser samma spelare med olika namnvarianter från olika källor, och att spåra datans ursprung. Dessa krävde problemlösning och noggrann programmering för att säkerställa dataintegritet och spårbarhet. Resultatet visade att applikationen visualiserade datainkonsistenser effektivt, vilket gjorde det möjligt för användarna att identifiera och förstå avvikelserna. Visualiseringarna underlättade upptäckten av inkonsekvenser, vilket hjälpte tränare och lagledare att vidta nödvändiga åtgärder för att förbättra datakvaliteten. Exempel på resultat kan ses i figur 13 och 14 i avsnitten 4.1.1 och 4.1.2.

Vid ett senare tillfälle planeras ytterligare ett möte där applikationen, nu när den är färdigutvecklad, kommer att demonstreras igen. Vid detta möte kommer fler användartester att utföras för att säkerställa att alla funktioner fungerar som de ska och för att samla in ytterligare feedback för framtida förbättringar.

Verifiering av dataanalysens resultat genomfördes genom en noggrann granskning av de statistiska metoderna och inferensresultaten. Analysen med bayesiansk nätverksmodellen visade sig vara särskilt effektiv för att identifiera de mest inflytelserika variablerna som påverkar spelarens rating och prestationer. För att säkerställa tillförlitligheten av dessa resultat genomfördes korsvalidering och jämförelser med tidigare forskning.

För framtida arbete rekommenderas flera förbättringar och utvecklingsområden för både applikationen och dataanalysen. När det gäller applikationen bör utvecklingen fokusera på att implementera säker inloggningsfunktionalitet för att skydda data och begränsa åtkomsten till auktoriserade användare. En mer avancerad logik för att hantera namnvariationer, såsom användning av fuzzy matching-

algoritmer eller maskininlärning, kan utvecklas för att identifiera och sammanföra varianter av samma namn. Dessutom kan övergången till en dokumentbaserad databas, som MongoDB, övervägas för att hantera större och mer komplexa datamängder mer effektivt och för att förbättra prestanda och flexibilitet vid dynamisk datahantering.

Inom dataanalysen skulle framtida arbete kunna fokusera på att utveckla mer objektiva och standardiserade mätmetoder för att minska subjektiviteten i coachernas bedömningar. Detta skulle kunna inkludera användning av tekniska verktyg eller algoritmer för att bedöma spelarnas prestationer. Dessutom skulle insamling av data över flera säsonger eller från flera lag kunna öka generaliserbarheten av resultaten och möjliggöra en mer robust statistisk analys. Vidare kan analysen från detta arbete ligga till grund för att utveckla mer komplexa systemmodeller som kan hjälpa till att förstå sambanden mellan olika variabler och prestationer, samt hur dessa sammanfaller med mätbar data. Det kan även vara värdefullt att utforska mer sofistikerade statistiska modeller som kan hantera komplexiteten i datan och minska påverkan av outliers, såsom robusta regressionsmodeller eller maskininlärningsmetoder.

Genom att genomföra dessa förbättringar och fortsätta att utvärdera applikationens prestanda och användarupplevelse, samt genom att integrera ytterligare avancerade dataanalyser, kan applikationen ytterligare stärkas för att bättre stödja tränare och lagledare i deras arbete med att analysera och förbättra spelarnas prestationer.

6 Slutsatser

Detta examensarbete har utvecklat en applikation för att förbättra hanteringen och analysen av fotbollsstatistik för ungdomslag, med fokus på att integrera data från flera källor och visualisera dessa på ett användarvänligt sätt. Applikationen använder både relationsdatabaser och grafdatabaser, och inkluderar dynamisk datahantering och visuell representation genom diagram och nätverksgrafer.

Arbetet har visat att applikationen förbättrar möjligheterna att identifiera och förstå datainkonsistenser från olika statistikplattformar. Användartester och intern validering bekräftade att applikationen är praktiskt användbar och effektiv för att hantera och analysera fotbollsstatistik, vilket stöder mer informerade och effektiva beslut inom ungdomsfotboll.

Dataanalysen, som genomfördes med hjälp av bayesianska nätverksmodeller, visade att vissa variabler, såsom Chains PG, Tactic och Technique, har en betydande inverkan på spelarnas prestationer. Dessa fynd är viktiga för tränare och lagledare eftersom de belyser vilka aspekter av en spelares prestation som bör prioriteras för att uppnå bästa möjliga resultat. Genom att använda "Played Minute = 90" som bevis kunde vi fokusera på spelare som spelat hela matchen och identifiera de faktorer som påverkar spelarens rating och prestationer mest, vilket ger praktiska insikter för optimering av träningsstrategier.

Resultaten från detta arbete stämmer överens med tidigare forskning som understryker vikten av dataintegration och effektiv visualisering i sportanalytik. Studier av Bai *et al.* (2) och Wexler *et al.* (4) betonade vikten av att hantera stora datamängder och att välja rätt teknik för dataframställning, vilket reflekteras i applikationens design och utveckling. Vidare visade Vicknair *et al.* (7) att grafdatabaser är effektiva för att hantera komplexa relationer, vilket har tillämpats framgångsrikt i detta projekt. Resultaten från dataanalysen bekräftar också tidigare forskning som framhäver fördelarna med bayesianska nätverksmodeller för att hantera osäkerheter och komplexa beroenden mellan variabler.

Trots dessa framgångar finns det begränsningar i studien som bör beaktas. Den subjektiva naturen av coachernas bedömningar kan ha påverkat resultaten, vilket understryker behovet av att utveckla mer objektiva och standardiserade mätmetoder. Dessutom är generaliserbarheten av resultaten begränsad på grund av den specifika kontexten och den relativt lilla storleken på datasetet.

För framtida utveckling rekommenderas en vidareutveckling av applikationen för att inkludera fler automatiserade funktioner, ytterligare användartester och ett utökat användargränssnitt som kan hantera ännu fler datatyper och ge ytterligare anpassningsmöjligheter. En utforskning av dokumentbaserade databaser som MongoDB kan också övervägas för att hantera större och mer komplexa datamängder effektivt. Vidareutveckling av grafdatabasfunktionaliteten för att inkludera relationer mellan spelare och kvalitativa data samt förbättringar i hanteringen av namnmatchning skulle ytterligare stärka applikationen.

Sammanfattningsvis visar detta arbete att en välutvecklad applikation, kombinerad med avancerad dataanalys, kan erbjuda betydande fördelar för hanteringen av fotbollsstatistik. Genom att fortsätta utveckla och förbättra dessa verktyg kan vi förvänta oss ännu större insikter i spelarprestationer och därmed bättre stödja tränare och lagledare i deras strävan att maximera spelarnas potential och lags framgång.

Källförteckning


- [1] Sarmento D. Chapter 22: Correlation Types and When to Use Them [Internet]. ademos.people.uic.edu. 2023 [citerad 2024-07-15]. Hämtad från: <https://ademos.people.uic.edu/Chapter22.html>
- [2] Bai Z, Bai X. Sports Big Data: Management, Analysis, Applications, and Challenges. lin chuan, editor. Complexity [Internet]. 2021 Jan 30;2021:1–11. Hämtad från: <https://www.hindawi.com/journals/complexity/2021/6676297/>
- [3] Few S. Information dashboard design : the effective visual communication of data. Sebastopol, Ca: O'reilly; 2006.
- [4] Wexler S, Shaffer J, Cotgreave A. The Big Book of Dashboards : Visualizing Your Data Using Real-World Business Scenarios. Hoboken, Nj: John Wiley & Sons; 2017.
- [5] Chart.js. Bar · Chart.js documentation [Internet]. www.chartjs.org. 2024 [uppdaterad 2024-04-08; citerad 2024-04-25]. Hämtad från: <https://www.chartjs.org/docs/latest/charts/bar.html>
- [6] Vaughan J, Mallett CJ, Potrac P, López-Felip MA, Davids K. Football, Culture, Skill Development and Sport Coaching: Extending Ecological Approaches in Athlete Development Using the Skilled Intentionality Framework. Frontiers in Psychology. 2021 Jul 8;12(7).
- [7] Vicknair C, Macias M, Zhao Z, Nan X, Chen Y, Wilkins D. A comparison of a graph database and a relational database. Proceedings of the 48th Annual Southeast Regional Conference on - ACM SE '10. 2010;
- [8] Microsoft. Vad är databaser? [Internet]. azure.microsoft.com. 2023 [uppdaterad 2023-10-02; citerad 2024-04-30]. Hämtad från: <https://azure.microsoft.com/sv-se/resources/cloud-computing-dictionary/what-are-databases/>
- [9] Saad M, Zhang Y, Tian J, Jia J. A graph database for life cycle inventory using Neo4j. Journal of Cleaner Production [Internet]. 2023 Mar 20 [citerad 2024-05-18];393:136344. Hämtad från: <https://www.sciencedirect.com/science/article/pii/S0959652623005024>
- [10] Monteiro J, Sá F, Bernardino J. Experimental Evaluation of Graph Databases: JanusGraph, Nebula Graph, Neo4j, and TigerGraph. Applied Sciences [Internet]. 2023 Jan 1 [citerad 2024-05-18];13(9):5770. Hämtad från: <https://www.mdpi.com/2076-3417/13/9/5770>
- [11] IONOS. Object-oriented databases [Internet]. IONOS Digitalguide. 2023 [uppdaterad 2023-01-18; citerad 2024-04-30]. Hämtad från: <https://www.ionos.co.uk/digitalguide/hosting/technical-matters/object-oriented-databases/>
- [12] Mishra S. Object-Oriented Databases And Their Advantages [Internet]. hackernoon.com. 2022 [uppdaterad 2022-09-12; citerad 2024 Apr 30]. Hämtad från: <https://hackernoon.com/object-oriented-databases-and-their-advantages>
- [13] Field AP. Discovering statistics using SPSS. 3rd ed. London: SAGE Publications; 2009.
- [14] Ghasemi A, Zahediasl S. Normality Tests for Statistical Analysis: a Guide for Non-Statisticians. International Journal of Endocrinology and Metabolism [Internet]. 2012 Apr 20 [citerad 2024-08-05];10(2):486–9. Hämtad från: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3693611/>

- [15] Mukaka MM. Statistics corner: A guide to appropriate use of correlation coefficient in medical research. *Malawi medical journal: the journal of Medical Association of Malawi* [Internet]. 2012 Sep 24 [citerad 2024-08-05];24(3):69–71. Hämtad från: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3576830/>
- [16] Bonett DG, Wright TA. Sample size requirements for estimating pearson, kendall and spearman correlations. *Psychometrika*. 2000 Mar;65(1):23–8.
- [17] Korb KB, Nicholson AE. *Bayesian Artificial Intelligence*. CRC Press; 2010.
- [18] Thomas Dyhre Nielsen, Finn Verner Jensen, Springerlink (Online Service. *Bayesian Networks and Decision Graphs* [Internet]. New York, Ny: Springer New York; 2007 [citerad 2024 Jul 18]. Hämtad från: <https://link.springer.com/book/10.1007/978-0-387-68282-2>
- [19] Ding J. Probabilistic Inferences in Bayesian Networks [Internet]. ar5iv. 2024 [citerad 2024-08-08]. Hämtad från: <https://ar5iv.labs.arxiv.org/html/1011.0935>
- [20] Needham CJ, Bradford JR, Bulpitt AJ, Westhead DR. Inference in Bayesian networks. *Nature Biotechnology* [Internet]. 2006 Jan [citerad 2024-08-08];24(1):51–3. Hämtad från: <https://www.nature.com/articles/nbt0106-51.pdf>
- [21] Elgabry O. Component Based Architecture [Internet]. OmarElgabry's Blog. 2019 [uppdaterad 2021-04-01; citerad 2024-04-25]. Hämtad från: <https://medium.com/omarelgabrys-blog/component-based-architecture-3c3c23c7e348>
- [22] Nylund A. Vad är React? [Internet]. IT-Högskolan. 2023 [uppdaterad 2023-10-16; citerad 2024-04-26]. Hämtad från: <https://www.iths.se/vad-ar-react/>
- [23] Collings T. Controller-Service-Repository [Internet]. Medium. 2021 [uppdaterad 2021-08-21; citerad 2024-04-26]. Hämtad från: <https://tom-collings.medium.com/controller-service-repository-16e29a4684e5>
- [24] Bishop CM. *Pattern Recognition and Machine Learning* [Internet]. Springer; 2006 [citerad 2024-08-07]. Hämtad från: <https://www.microsoft.com/en-us/research/uploads/prod/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>
- [25] Murphy KP. *Machine learning: a probabilistic perspective* [Internet]. Cambridge (Ma): Mit Press; 2012 [citerad 2024-08-07]. Hämtad från: https://www.academia.edu/35856835/Machine_Learning_A_Probabilistic_Perspective
- [26] Györfödi CA, Dumşeu-Burescu DV, Györfödi RŞ, Zmaranda DR, Bandici L, Popescu DE. Performance Impact of Optimization Methods on MySQL Document-Based and Relational Databases. *Applied Sciences*. 2021 Jul 23;11(15):6794.
- [27] Bonteanu AM, Tudose C. Performance Analysis and Improvement for CRUD Operations in Relational Databases from Java Programs Using JPA, Hibernate, Spring Data JPA. *Applied Sciences* [Internet]. 2024 Jan 1 [citerad 2024-05-18];14(7):2743. Hämtad från: <https://www.mdpi.com/2076-3417/14/7/2743>
- [28] Repici DJ. The Comma Separated Value (CSV) File Format [Internet]. www.creativyst.com. 2024 [uppdaterad 2024-03-16; citerad 2024-04-20]. Hämtad från: <https://www.creativyst.com/Doc/Articles/CSV/CSV01.shtml>
- [29] Amazon Web Services. What is Full Stack Development? [Internet]. Amazon Web Services, Inc. 2024 [uppdaterad 2024-04-19; citerad 2024-04-21]. Hämtad från: <https://aws.amazon.com/what-is/full-stack-development/>


- [30] Amazon Web Services. What is an API? [Internet]. Amazon Web Services, Inc. 2024 [uppdaterad 2024-04-09; citerad 2024-04-24]. Hämtad från: <https://aws.amazon.com/what-is/api/>
- [31] Ameer H, Njah H, Jamoussi S. Merits of Bayesian networks in overcoming small data challenges: a meta-model for handling missing data. *International Journal of Machine Learning and Cybernetics* [Internet]. 2022-06-27 [citerad 2024-08-21];14. Hämtad från: <https://link.springer.com/article/10.1007/s13042-022-01577-9>
- [32] Fuster-Parra P, Tauler P, Bennasar-Veny M, Ligęza A, López-González AA, Aguiló A. Bayesian network modeling: A case study of an epidemiologic system analysis of cardiovascular risk. *Computer Methods and Programs in Biomedicine* [Internet]. 2016 Apr [citerad 2024-08-20];126:128–42. Hämtad från: https://www.sciencedirect.com/science/article/pii/S0169260715301140?fr=RR-2&ref=pdf_download&rr=8b692df7d8d42d6e
- [33] Pierpalo D'Urso, Livia De Giovanni, Vitale V. A Bayesian network to analyse basketball players' performances: a multivariate copula-based approach. *Annals of Operations Research* [Internet]. 2022 Aug 9 [citerad 2024-08-20];325(1):419–40. Hämtad från: <https://link.springer.com/article/10.1007/s10479-022-04871-5>
- [34] Olmedilla A, Rubio VJ, Fuster-Parra P, Pujals C, García-Mas A. A Bayesian Approach to Sport Injuries Likelihood: Does Player's Self-Efficacy and Environmental Factors Plays the Main Role? *Frontiers in Psychology* [Internet]. 2018 Jul 6 [citerad 2024-08-20];9(1174). Hämtad från: <https://www.frontiersin.org/journals/psychology/articles/10.3389/fpsyg.2018.01174/full>

Bilagor


Bilaga A – Resultat för dataanalysen av plattformen SoccerLab




Figur A:1 – Resultat för normalfördelningen med histogram




Figur A: 2 – Resultat för normalfördelning med QQ-plottningar



Figur A: 3 – Resultat för korrelationsmatris (Pearson)




Figur A: 4 – Resultat för korrelationsmatris (Spearman)




Figur A: 5 – Resultat för korrelationsmatris (Kendall)


Bilaga B – Resultat för dataanalysen av plattformen EyeBall




Figur B: 1 – Resultat för normalfördelning med histogram




Figur B: 2 – Resultat för normalfördelningen med QQ-plottningar



Figur B: 3 – Resultat för korrelationsmatris (Pearson)




Figur B: 5 – Resultat för korrelationsmatris (Spearman)




Figur B: 5 – Resultat för korrelationsmatris (Kendall)

Bilaga C – Resultat för dataanalys av plattformen PlayMaker



Figur C: 1 – Resultat för normalfördelningen med histogram



Figur C: 2 – Resultat för normalfördelningen med QQ-plottningar

Bilaga D – Datavariabler för plattformarna

Plattform SoccerLab

Variabelnamn	Datatyp	Beskrivning
Position	String	Positionen av spelaren
Played Minute	Integer	Antal spelade minuter under en match
Mentality	Integer	Mäter spelarens mentala egenskaper, såsom beslutsfattande, fokus och stresshantering.
Technique	Integer	Beskriver spelarens tekniska färdigheter, inklusive bollkontroll, passningsspel och skottprecision.
Tactic	Integer	Reflekterar spelarens taktiska förståelse och förmåga att läsa spelet, positionering och strategisk medvetenhet.
Physique	Integer	Mäter spelarens fysiska egenskaper, som styrka, snabbhet och uthållighet
Total Score	Double	Genomsnittet av variablerna mentalitet, teknik, taktik och fysik.

Plattform Eyeball

Variabelnamn	Datatyp	Beskrivning
rating	Double	Spelarens betyg baserat på prestationer
goalsScored	Integer	Antal mål som spelaren har gjort under matchen
assists	Integer	Antal gånger spelaren har assisterat till ett mål.
goalsOwn	Integer	Antal självmål som spelaren har gjort under matchen.
shots	Integer	Antal skott som spelaren har tagit under matchen.
offsides	Integer	Antal gånger spelaren har blivit avblåst för offside.
freekicks	Integer	Antal frisparkar som spelaren har fått eller orsakat.


corners	Integer	Antal hörnor som spelaren har orsakat eller fått.
throwIns	Integer	Antal inkast som spelaren har utfört.
Fouls	Integer	Antal regelöverträdelser som spelaren har begått.
yellowCards	Integer	Antal gula kort som spelaren har fått.
redCards	Integer	Antal röda kort som spelaren har fått.

Plattform PlayMaker

Variabelnamn	Datatyp	Beskrivning
Actions PG	Double	Antal aktioner totalt per spelad match (passningar, dribblingar, förflyttningar med bollen, skott, tacklingar, interceptioner etc.)
Aerials PG	Double	Luftdueller per spelad match
Assists PG	Double	Assist per spelad match
Blocks PG	Double	Blockerade skott per spelad match
Carries PG	Double	Antal förflyttningar med bollen per spelad match
Chains PG	Double	Antal bollinnehavsekvenser per spelad match
Challenges PG	Double	Antal utmaningar per spelad match
CIB PG	Double	Antal förflyttningar in i straffområdet per spelad match
Clearances PG	Double	Rensningar per spelad match
Crosses PG	Double	Inlägg per spelad match
Dribbles PG	Double	Dribblingar per spelad match
Efficiency	Double	Effektivitet vid utförda aktioner
Fouls PG	Double	Regelbrott begångna per spelad match
Goal Kicks PG	Integer	Lyckade målsparkar per spelad match

Goals PG	Integer	Mål gjorda per spelad match
Interceptions PG	Double	Antal lyckade brytningar per spelad match
Key Passes PG	Double	Nyckelpassningar per spelad match, passningar som leder till skott men inte resulterar i mål
Lidmark Index	Double	Mäter hur konsekvent en spelare kan prestera på en hög nivå. Ju högre värde, desto mer konsekvent är spelaren.
Long Balls PG	Double	Lyckade långa passningar över 25 meter per spelad match
Lost Balls PG	Double	Antal förlorade bollinnehav genom dåliga passningar, mottagningar eller misslyckade dribblingar/förflyttningar per spelad match
Passes PG	Double	Antal lyckade passningar per spelad match
Playmaker Rank	Double	Spelfördelarens AI-betyg, baserat på spelarens påverkan på sitt lag. Spelarens prestationer jämförs med historiska matcher och med spelare på samma position.
Points PG	Integer	Mål och assist per spelad match
Possession Actions PG	Double	Antal aktioner i bollinnehav per spelad match (passningar, dribblingar, förflyttningar med bollen, skott etc.)
Receptions PG	Double	Antal mottagna passningar per spelad match
Saves PG	Integer	Antal räddningar per spelad match
Shot Assists PG	Integer	Antal assist och nyckelpassningar per spelad match, passningar som leder till skott
Tackles PG	Integer	Antal lyckade tacklingar per spelad match
xG PG	Double	Förväntade mål per spelad match

Bilaga E – Resultat för de summerade betygen samt AIK:s kvalitativa betyg



Figur E:1 – Resultat från regressionsplottningarna

